
Analítica de Datos

Sesión 01. De los datos a la decisión

Fundamentos, CRISP-DM, preparación de datos
y primer análisis exploratorio con Python y Pandas

Luis Miguel Gómez Meneses

Universidad Cooperativa de Colombia

Ingeniería de Software — Séptimo semestre

Cómo trabajaremos hoy

Bloque	Contenido	Tiempo
Teoría 1	Problema empresarial y tipos de analítica	30 min
Lab 1	Primer contacto con los datos	25 min
Teoría 2	CRISP-DM y comprensión de los datos	25 min
Lab 2	Comprensión y calidad	30 min
Teoría 3	Preparación de datos y calidad	20 min
Lab 3	Preparación básica	35 min
Teoría 4	Análisis exploratorio de datos	15 min
Lab 4	EDA inicial e interpretación	45 min

Las diapositivas con fondo claro y título naranja corresponden a trabajo en Google Colab.

Antes de cualquier definición: una situación

Andina Retail

Cadena con 42 tiendas físicas y un canal en línea. Durante los últimos seis meses las ventas cayeron un 12 % frente al mismo periodo del año anterior. El comité directivo exige una respuesta en una semana.

INFORMACIÓN DISPONIBLE

- Transacciones históricas y clientes
- Productos, precios y descuentos
- Campañas, regiones y canales

PREGUNTAS DEL COMITÉ

- ¿Qué ocurrió y dónde ocurrió?
- ¿Por qué ocurrió?
- ¿Qué ocurrirá el próximo trimestre?
- ¿Qué decisión tomamos?

Hay datos. Todavía no hay respuesta.

Qué es, y qué no es, la analítica de datos


Definición operativa

Conjunto de procesos, métodos y herramientas que transforman datos en **evidencia útil** para responder preguntas y apoyar decisiones bajo incertidumbre.



Delimitación: el aprendizaje automático es una técnica dentro del paso de análisis, no un sinónimo de analítica de datos.

Cuatro niveles, cuatro preguntas



Los niveles superiores no reemplazan a los inferiores: dependen de ellos.

El mismo problema visto desde los cuatro niveles

Nivel	Pregunta sobre Andina	Enfoque	Salida esperada
Descriptiva	¿Cuánto cayeron las ventas y dónde?	Agregación por región y mes	Cuadro de mando con la magnitud
Diagnóstica	¿Qué distingue a las tiendas que cayeron?	Comparación entre grupos	Factores asociados priorizados
Predictiva	¿Cuánto se venderá el próximo trimestre?	Modelo de series de tiempo	Proyección con intervalo
Prescriptiva	¿Dónde invertir el presupuesto promocional?	Optimización con restricciones	Plan de asignación

Discusión relámpago — 5 min

Clasifique: (a) ¿qué clientes tienen mayor riesgo de no volver? (b) ¿por qué Hogar cayó más que Tecnología? (c) ¿qué descuento maximiza el margen?

¿Con qué datos contamos realmente?

Laboratorio 1 · 25 min

Propósito

Abrir por primera vez el archivo de transacciones de Andina Retail y describir su contenido antes de analizar nada.

Herramientas

- **Python:** lenguaje de trabajo
- **Pandas:** biblioteca para datos tabulares
- **Colab:** entorno de ejecución

El DataFrame

Estructura tabular en memoria: columnas con nombre y tipo, filas indexadas. Es el objeto central de Pandas.



¿Qué tamaño y qué variables tiene el conjunto?

Laboratorio 1 · 25 min

```
import pandas as pd

df = pd.read_csv("ventas.csv")

df.head()
df.shape
df.columns
```

Responda con la salida

- ¿Cuántas observaciones y cuántas variables?
- ¿Qué representa una fila: un cliente, un producto o una transacción?
- ¿Qué columna identifica cada registro?

La unidad de análisis condiciona toda agregación posterior.

¿El tipo de dato corresponde al significado?

Laboratorio 1 · 25 min

```
df.info()
```

```
df.dtypes
```


Tipo computacional: lo que Pandas dedujo al leer el archivo.

Significado de la variable

- fecha: temporal, no texto
- id_cliente: identificador, no cantidad
- ciudad, canal: categóricas
- unidades, ventas: numéricas

Anote las discrepancias: son el primer insumo del bloque de preparación.

El ciclo CRISP-DM



Naranja: retornos entre etapas y reinicio del ciclo. Iterar es lo normal.

Hoy recorreremos las tres primeras etapas.

Un proyecto de analítica no comienza escogiendo un algoritmo: comienza definiendo el problema.

Etapa 1. Business Understanding

Objetivo

Traducir un problema de la organización en un objetivo analítico con criterio de éxito medible.

Preguntas fundamentales

- ¿Qué decisión va a cambiar con este proyecto?
- ¿Cómo se mide el éxito en términos del negocio?
- ¿Qué restricciones existen?

En Andina Retail

- Decisión: dónde concentrar el esfuerzo comercial
- Éxito: recuperar 4 puntos porcentuales en dos trimestres
- Restricción: presupuesto promocional fijo

Riesgo frecuente

Definir el objetivo como “construir un modelo” en lugar de “apoyar una decisión”.

Etapla 2. Data Understanding

Objetivo

Determinar si los datos disponibles permiten responder la pregunta formulada, y con qué limitaciones.

Preguntas fundamentales

- ¿Qué representa cada variable y quién la produce?
- ¿Qué periodo y qué cobertura tienen los registros?
- ¿Qué problemas de calidad aparecen?

Actividades típicas

- Perfilado descriptivo del conjunto
- Verificación de tipos, faltantes y duplicados
- Revisión de categorías y rangos

Resultado esperado

Diccionario de datos, informe de calidad y primeras hipótesis.

El Laboratorio 2 es exactamente esta etapa.

Etapas 3 a 6: el resto del ciclo

Etapas	Pregunta que resuelve	Resultado
Data Preparation	¿Qué transformaciones exige el análisis?	Conjunto reproducible y documentado
Modeling	¿Qué técnica corresponde a la pregunta?	Modelos ajustados y validados
Evaluation	¿Se cumplió el criterio de negocio?	Decisión de continuar o iterar
Deployment	¿Quién usará el resultado y cómo?	Solución operando y monitoreada

Advertencia: una métrica técnica alta no significa que el problema empresarial esté resuelto.

Propósito

Perfilar el conjunto y documentar todo lo que impediría analizarlo tal como está.

Cuatro verificaciones

- Rangos y magnitudes plausibles
- Valores faltantes
- Registros duplicados
- Consistencia de las categorías

Ningún hallazgo se corrige en este laboratorio: se detecta, se describe y se registra.

¿Los valores son plausibles? ¿Falta información?

Laboratorio 2 · 30 min

```
df.describe()
```

```
df.isnull().sum()
```

Qué observar

- ¿El mínimo y el máximo de ventas son razonables?
- ¿La media se separa mucho de la mediana?
- ¿En qué variables faltan datos y en qué proporción?
- ¿Coincide count con el número de filas?

¿Hay duplicados o categorías inconsistentes?

Laboratorio 2 · 30 min

```
df.duplicated().sum()
```

```
df["ciudad"].value_counts()
```

```
df["categoria"].value_counts()
```

```
df["canal"].value_counts()
```

Qué observar

- ¿Aparece la misma ciudad escrita de varias formas?
- ¿Cuántas categorías esperaba y cuántas obtuvo?
- ¿Un duplicado exacto es un error o una venta repetida legítima?

Una categoría mal codificada divide un grupo real en dos grupos falsos.

Variable	Problema	Evidencia	Riesgo para el análisis
.....			
.....			
.....			
.....			

Complete la tabla en el cuaderno. **La columna de riesgo es la que se evalúa:** exige explicar qué conclusión quedaría mal fundamentada.

Qué significa preparar los datos

Definición

Conjunto de transformaciones que convierten los datos disponibles en un conjunto **analizable, reproducible y documentado**, sin alterar el fenómeno que representan.

Qué incluye

- Corrección de tipos
- Normalización de categorías
- Tratamiento de faltantes y duplicados
- Derivación de nuevas variables

Qué no es


No es eliminar todo lo incómodo. Cada decisión de limpieza modifica el resultado del análisis y debe quedar justificada y registrada.

Dimensiones de calidad de los datos

Dimensión	Pregunta	Cómo se verifica
Compleitud	¿Faltan valores o registros?	Conteo de nulos por variable
Consistencia	¿La misma entidad se codifica siempre igual?	Conteo de categorías únicas
Exactitud	¿El valor corresponde al hecho real?	Rangos, mínimos y máximos
Unicidad	¿Hay registros repetidos?	Conteo de duplicados
Trazabilidad	¿De dónde vino y quién lo transformó?	Documentación del proceso

Estas cinco preguntas son el guion del informe de calidad de cualquier proyecto.

Por qué los datos reales nunca llegan listos



Los defectos se originan en el sistema que produce los datos: **como ingenieros de software ustedes están en el origen del problema.**

¿Qué transformaciones mínimas hacen utilizable el dataset?

Laboratorio 3 · 35 min

Propósito

Resolver los hallazgos registrados en el Laboratorio 2 y verificar que la transformación funcionó.



Toda transformación se ejecuta tres veces: se observa, se aplica y se comprueba.

¿Podemos trabajar con el tiempo?

Laboratorio 3 · 35 min

```
df["fecha"].dtype

df["fecha"] = pd.to_datetime(
    df["fecha"]
)

df["fecha"].dtype
df["fecha"].min()
df["fecha"].max()
```

Qué habilita el cambio

- Ordenar cronológicamente
- Agrupar por mes o trimestre
- Construir una serie de tiempo

Verifique

¿El periodo cubierto corresponde al que esperaba el comité?

¿Cuántas ciudades hay realmente?

Laboratorio 3 · 35 min

```
df["ciudad"].value_counts()

df["ciudad"] = (
    df["ciudad"]
        .str.strip()
        .str.lower()
        .str.title()
)

df["ciudad"].value_counts()
```

Antes y después

Compare el número de categorías y el conteo de la ciudad más frecuente.

Documente la decisión

¿Por qué normalizar y no eliminar los registros mal escritos?

¿Qué hacemos con duplicados y faltantes?

Laboratorio 3 · 35 min

```
df = df.drop_duplicates()

df["descuento"] = (
    df["descuento"].fillna(0)
)

falta = df["ventas"].isnull()
df.loc[falta, "ventas"] = (
    df["unidades"]
    * df["precio_unitario"]
    * (1 - df["descuento"])
)

df.isnull().sum()
```

Justifique cada línea

- Suponer descuento cero: ¿es razonable o sesga el margen?
- Reconstruir ventas: ¿qué supuesto introduce?
- ¿Cuándo sería preferible descartar el registro?

Verifique de nuevo la calidad al terminar.

Análisis exploratorio de datos

Definición

Examen sistemático de un conjunto ya preparado para **describir su comportamiento, detectar patrones y formular hipótesis** antes de modelar.

Para qué sirve

- Conocer la forma de las variables
- Comparar grupos
- Detectar valores extremos
- Orientar la pregunta analítica

Qué no es todavía

No es inferencia ni modelado. No confirma hipótesis: las genera y las hace explícitas.

Las cuatro miradas del EDA

Mirada	Pregunta	Instrumento
Distribución	¿Cómo se reparten los valores?	Histograma
Tendencia central y dispersión	¿Cuál es el valor típico y cuánto varía?	Media, mediana, desviación
Agrupaciones	¿Se comportan igual todos los grupos?	groupby, barras
Valores extremos	¿Hay registros que dominan el resultado?	Boxplot, máximos

Regla: cuando media y mediana difieren mucho, la media deja de representar al conjunto.

¿Qué nos dicen los datos sobre la caída de ventas?

Laboratorio 4 · 45 min

Propósito

Producir evidencia interpretable sobre el comportamiento de las ventas, usando el conjunto ya preparado.

Ruta del laboratorio

1. Valor típico y dispersión
2. Comparación entre ciudades y categorías
3. Distribución y valores extremos
4. Conclusión para el comité

Cada resultado debe traducirse en una frase que un directivo pueda leer.

¿Cuánto vende una transacción típica?

Laboratorio 4 · 45 min

```
df["ventas"].describe()
```

```
df["ventas"].mean()  
df["ventas"].median()  
df["ventas"].std()
```

Interprete

- ¿Media o mediana para informar al comité? Justifique.
- ¿Qué indica una desviación mayor que la media?
- ¿Qué distancia hay entre el percentil 75 y el máximo?

¿Se comportan igual todas las ciudades y categorías?

Laboratorio 4 · 45 min

```
ventas_ciudad = (  
    df.groupby("ciudad")["ventas"]  
        .sum()  
        .sort_values(ascending=False)  
)  
  
df.groupby("categoria")["ventas"].agg(  
    ["count", "mean", "sum"]  
)
```

Interprete

- ¿Concentración o reparto homogéneo entre ciudades?
- ¿Alguna categoría vende poco pero factura mucho?
- ¿Qué diferencia hay entre volumen e ingreso?

¿Qué forma tiene la distribución de ventas?

Laboratorio 4 · 45 min

```
import matplotlib.pyplot as plt

df["ventas"].plot(kind="hist",
                  bins=40)

plt.xlabel("Ventas")
plt.show()

ventas_ciudad.plot(kind="bar")
plt.ylabel("Ventas totales")
plt.show()
```

Interprete

- ¿La distribución es simétrica o tiene cola larga?
- ¿Dónde se acumula la mayoría de las transacciones?
- ¿El gráfico de barras confirma lo que mostró el groupby?

¿Hay registros que dominan el resultado?

Laboratorio 4 · 45 min

```
df.boxplot(column="ventas")
plt.show()

df.boxplot(column="ventas",
            by="categoria")
plt.show()

cols = ["fecha", "ciudad",
        "categoria", "ventas"]
df.nlargest(5, "ventas")[cols]
```

Interprete

- ¿Los puntos fuera del bigote son errores o ventas legítimas?
- ¿Cómo cambian media y total si se excluyen?
- ¿Qué decidiría y con qué justificación?

Un valor extremo no se elimina por ser incómodo, sino por ser incorrecto.

Entregable de la sesión

Cinco líneas dirigidas al comité directivo de Andina Retail. Cada afirmación debe apoyarse en un resultado obtenido hoy en el cuaderno.

Debe incluir

- Qué se puede afirmar con los datos
- Qué no se puede afirmar todavía
- Qué transformación fue necesaria y por qué

Criterio de evaluación

Se evalúa la interpretación, no la ejecución del código. **Ejecutar código no equivale a realizar analítica de datos.**

¿Dónde estamos dentro de CRISP-DM?

Etapas recorridas hoy

- **Business Understanding:** problema, preguntas y criterio de éxito
- **Data Understanding:** perfilado y registro de hallazgos
- **Data Preparation:** tipos, categorías, faltantes y duplicados

Próxima sesión

- EDA en profundidad y relaciones entre variables
- Tratamiento formal de valores atípicos
- Preparación para la etapa de modelado

Traer

Cuaderno ejecutado y las cinco líneas de conclusión.

Problema → datos → preguntas → análisis → evidencia → decisión.