
Analítica de Datos

Sesión 01. De los datos a la decisión

Fundamentos, CRISP-DM, preparación de datos
y primer análisis exploratorio con Python y Pandas

Luis Miguel Gómez Meneses

Universidad Cooperativa de Colombia

Ingeniería de Software — Séptimo semestre

Cómo trabajaremos hoy

Bloque	Contenido	Tiempo
Teoría 1	Problema empresarial y tipos de analítica	30 min
Lab 1	Primer contacto con los datos	25 min
Teoría 2	CRISP-DM y comprensión de los datos	25 min
Lab 2	Comprensión y calidad	30 min
Teoría 3	Preparación de datos y calidad	20 min
Lab 3	Preparación básica	35 min
Teoría 4	Análisis exploratorio de datos	15 min
Lab 4	EDA inicial e interpretación	45 min

Las diapositivas con fondo claro y título naranja corresponden a trabajo en Google Colab.

Antes de cualquier definición: una situación

Andina Retail

Andina Retail es una empresa de comercio minorista que comercializa productos de tecnología, hogar, deportes y moda a través de diferentes canales de venta. La gerencia desea comprender el comportamiento de las ventas e identificar diferencias entre productos, categorías, ciudades y canales para apoyar sus decisiones comerciales.

INFORMACIÓN DISPONIBLE

- Historial de ventas y fechas
- Clientes y productos
- Categorías, unidades, precios y descuentos
- Ciudades y canales de venta

PREGUNTAS DEL COMITÉ

- ¿Cómo se han comportado las ventas?
- ¿Qué productos y categorías generan mayores ventas?
- ¿En qué ciudades y canales se concentran?
- ¿Qué patrones relevantes presentan las transacciones?

Qué es, y qué no es, la analítica de datos


Definición operativa

Conjunto de procesos, métodos y herramientas que transforman datos en **evidencia útil** para responder preguntas y apoyar decisiones bajo incertidumbre.




Delimitación: el aprendizaje automático es una técnica dentro del paso de análisis, no un sinónimo de analítica de datos.

Cuatro niveles, cuatro preguntas



Los niveles superiores no reemplazan a los inferiores: dependen de ellos.

¿Qué diferencia a cada tipo de analítica?



La diferencia fundamental está en el propósito del análisis y en la pregunta que busca responder.

El mismo problema visto desde los cuatro niveles

Nivel	Pregunta sobre Andina	Enfoque	Salida esperada
Descriptiva	¿Cómo se han comportado las ventas?	Resumir y comparar datos históricos	Comportamiento observado de las ventas
Diagnóstica	¿Qué factores están asociados con las diferencias en ventas?	Comparar categorías, ciudades, canales y descuentos	Relaciones y factores relevantes
Predictiva	¿Cómo podrían comportarse las ventas futuras?	Modelar patrones a partir de datos históricos	Estimación de ventas futuras
Prescriptiva	¿Qué acciones comerciales convendría evaluar?	Evaluar alternativas para apoyar la decisión	Recomendación de acciones

Discusión

Clasifique cada pregunta: (a) ¿qué categoría generó mayores ventas?; (b) ¿qué factores están asociados con menores ventas?; (c) ¿cuánto podría venderse el próximo mes?; (d) ¿qué acción comercial convendría tomar?

¿Con qué datos contamos realmente?

Laboratorio 1 · 25 min

Propósito


Inspeccionar la estructura del dataset de Andina Retail, identificar las variables disponibles y comprender qué representa cada observación.

Herramientas

- **Python:** lenguaje utilizado para el análisis
- **Pandas:** biblioteca para datos tabulares
- **Colab:** entorno de ejecución

El DataFrame

Estructura de datos tabular de Pandas organizada en filas y columnas. Será el objeto principal sobre el que realizaremos el análisis.



```
import pandas as pd

df = pd.read_csv("ventas.csv")

df.head()
df.sample(5)
```

Observe antes de calcular

- ¿Qué parece representar cada fila?
- ¿Qué información contiene una transacción?
- ¿Qué variables reconoce?
- ¿Qué variables requieren interpretación?

Antes de analizar, debemos comprender qué representa el dataset.

```
df.shape
```

```
df.columns
```

```
df.info()
```

Interprete la salida

- ¿Cuántas observaciones tenemos?
- ¿Cuántas variables?
- ¿Cómo se llaman?
- ¿Qué tipos detectó Pandas?

Unidad de observación

¿Una fila representa un cliente, un producto o una transacción?

```
df.dtypes
```

Tipo computacional:

representación que Pandas asigna a cada columna.

Significado analítico

- fecha: temporal
- id_cliente: identificador
- producto: categórica
- categoria: categórica
- ciudad: categórica
- canal: categórica
- unidades: numérica
- precio_unitario: numérica
- descuento: numérica
- ventas: numérica

Paso 4 · ¿Qué valores contienen las variables?

Laboratorio 1 · 25 min

```
df["categoria"].unique()  
df["ciudad"].unique()  
df["canal"].unique()  
  
df["producto"].nunique()  
df["id_cliente"].nunique()
```

Interprete

- ¿Qué categorías existen?
- ¿En qué ciudades hay registros?
- ¿Qué canales aparecen?
- ¿Cuántos productos diferentes?
- ¿Cuántos clientes diferentes?


`unique()` muestra los valores distintos; `nunique()` indica cuántos existen.

Antes de continuar, debemos poder responder

1. ¿Cuál es la **unidad de observación**?
2. ¿Cuántas observaciones y variables contiene el dataset?
3. ¿Qué variables son numéricas, categóricas, temporales o identificadoras?
4. ¿Qué información tenemos disponible para analizar las ventas de Andina Retail?
5. ¿Qué preguntas analíticas podemos responder con estas variables?

Conocer la estructura no significa que los datos estén listos para ser analizados.

El ciclo CRISP-DM (Cross-Industry Standard Process for Data Mining)



Naranja: retornos entre etapas y reinicio del ciclo. Iterar es lo normal.

Hoy recorreremos las tres primeras etapas.

Un proyecto de analítica no comienza escogiendo un algoritmo: comienza definiendo el problema.

Etapa 1. Business Understanding

Objetivo

Traducir una necesidad de la organización en una **pregunta analítica clara**, vinculada con una decisión.

Preguntas fundamentales

- ¿Qué problema queremos comprender o resolver?
- ¿Qué decisión debe apoyar el análisis?
- ¿Qué resultado sería útil para la organización?
- ¿Qué restricciones debemos considerar?

En Andina Retail

- **Necesidad:** comprender el comportamiento de las ventas.
- **Pregunta:** ¿cómo varían las ventas según producto, categoría, ciudad, canal y tiempo?
- **Decisión:** identificar dónde conviene concentrar acciones comerciales.

Idea clave

El objetivo no es “construir un modelo”, sino **responder una pregunta que apoye una decisión.**

Etapas 2. Data Understanding

Objetivo

Comprender los datos disponibles y determinar si permiten responder la pregunta analítica, identificando sus limitaciones.

Preguntas fundamentales

- ¿Qué representa cada observación y cada variable?
- ¿Qué cobertura tienen los datos?
- ¿Qué problemas de calidad aparecen?

Actividades típicas

- Descripción inicial del conjunto
- Verificación de tipos y valores faltantes
- Identificación de duplicados
- Revisión de categorías y rangos

Resultado esperado

Comprensión documentada del conjunto, problemas de calidad identificados y primeras hipótesis sobre los datos.

El Laboratorio 1 inició esta etapa; el Laboratorio 2 profundizará en la calidad de los datos.

Etapas 3 a 6: el resto del ciclo

Etapas	Pregunta que resuelve	Resultado
Data Preparation	¿Cómo debemos limpiar y transformar los datos?	Datos preparados para el análisis o modelado
Modeling	¿Qué técnica permite responder la pregunta analítica?	Modelo o modelos entrenados
Evaluation	¿Los resultados responden adecuadamente al problema planteado?	Resultados evaluados y decisión de continuar o iterar
Deployment	¿Cómo se utilizará el resultado en la práctica?	Resultado integrado al proceso de decisión

¿Podemos confiar en estos datos?

Laboratorio 2 · 30 min

Propósito

Evaluar la calidad inicial del dataset e identificar problemas que puedan afectar el análisis y la interpretación de los resultados.

Cuatro verificaciones

- Rangos y valores plausibles
- Valores faltantes
- Registros duplicados
- Consistencia de las categorías

En este laboratorio no corregimos: detectamos, cuantificamos e interpretamos.

Paso 1 · ¿Los valores son plausibles? ¿Falta información?

Laboratorio 2 · 30 min

```
df.describe()
```

```
df.isnull().sum()
```

Qué observar

- ¿El mínimo y el máximo de ventas son razonables?
- ¿La media se separa mucho de la mediana?
- ¿En qué variables faltan datos?
- ¿Cuántos valores faltan en cada variable?
- ¿Coincide count con el número total de filas?

Un valor faltante no es automáticamente un error: primero debemos identificarlo y comprender su posible impacto.

Paso 2 · ¿Hay duplicados o categorías inconsistentes?

Laboratorio 2 · 30 min

```
df.duplicated().sum()
```

```
df["ciudad"].value_counts()
```

```
df["categoria"].value_counts()
```

```
df["canal"].value_counts()
```

Qué observar

- ¿Existen registros exactamente duplicados?
- ¿Aparece una misma ciudad escrita de varias formas?
- ¿Cuántas categorías diferentes aparecen?
- ¿Los valores de canal son consistentes?
- ¿Un duplicado exacto implica necesariamente un error?

Una categoría mal codificada puede dividir un mismo grupo en categorías artificialmente diferentes.

Variable	Problema	Evidencia	Riesgo para el análisis
.....			
.....			
.....			
.....			

Para cada hallazgo, explique **qué conclusión podría quedar mal fundamentada** si el problema no se trata adecuadamente.

Detectar un problema no implica decidir todavía cómo corregirlo.

¿Qué significa preparar los datos?

Definición

Conjunto de transformaciones que convierten los datos disponibles en un conjunto **analizable, reproducible y documentado**, procurando preservar el fenómeno que representan.

Qué incluye

- Corrección de tipos de datos
- Normalización de categorías
- Tratamiento de valores faltantes
- Revisión de registros duplicados
- Derivación de nuevas variables

Qué no es

No consiste en eliminar todo dato incómodo o inusual. Cada transformación puede afectar el análisis y, por tanto, debe estar **justificada y documentada**.

Dimensiones de calidad de los datos

Dimensión	Pregunta	Cómo podemos evaluarla
Compleitud	¿Faltan valores o registros?	Conteo y proporción de valores faltantes
Consistencia	¿La misma información se representa siempre de igual forma?	Revisión de categorías y codificaciones
Validez	¿Los valores cumplen las reglas y rangos esperados?	Revisión de dominios, formatos y rangos
Unicidad	¿Existen registros repetidos indebidamente?	Identificación de posibles duplicados
Trazabilidad	¿De dónde provienen los datos y qué transformaciones recibieron?	Documentación del proceso

La calidad no se resume en “tener datos completos”: existen diferentes dimensiones que deben evaluarse.

¿Por qué los datos reales rara vez llegan listos?



Conexión con Ingeniería de Software

La calidad del dato comienza en los sistemas que lo **capturan, validan, almacenan y transforman**. Un problema en cualquiera de estas etapas puede propagarse hasta el análisis o modelo final.

Preparar datos no solo corrige problemas: también evita que errores de origen se conviertan en conclusiones incorrectas.

¿Qué transformaciones mínimas hacen utilizable el dataset?

Laboratorio 3 · 35 min

Propósito

Resolver los hallazgos registrados en el Laboratorio 2 y verificar que la transformación funcionó.



Toda transformación se ejecuta tres veces: se observa, se aplica y se comprueba.

¿Podemos trabajar con el tiempo?

Laboratorio 3 · 35 min

```
df["fecha"].dtype

df["fecha"] = pd.to_datetime(
    df["fecha"]
)

df["fecha"].dtype
df["fecha"].min()
df["fecha"].max()
```

Qué habilita el cambio

- Ordenar cronológicamente
- Agrupar por mes o trimestre
- Construir una serie de tiempo

Verifique

¿El periodo cubierto corresponde al que esperaba el comité?

¿Cuántas ciudades hay realmente?

Laboratorio 3 · 35 min

```
df["ciudad"].value_counts()

df["ciudad"] = (
    df["ciudad"]
        .str.strip()
        .str.lower()
        .str.title()
)

df["ciudad"].value_counts()
```

Antes y después

Compare el número de categorías y el conteo de la ciudad más frecuente.

Documente la decisión

¿Por qué normalizar y no eliminar los registros mal escritos?

¿Qué hacemos con duplicados y faltantes?

Laboratorio 3 · 35 min

```
df = df.drop_duplicates()

df["descuento"] = (
    df["descuento"].fillna(0)
)

falta = df["ventas"].isnull()
df.loc[falta, "ventas"] = (
    df["unidades"]
    * df["precio_unitario"]
    * (1 - df["descuento"])
)

df.isnull().sum()
```

Justifique cada línea

- Suponer descuento cero: ¿es razonable o sesga el margen?
- Reconstruir ventas: ¿qué supuesto introduce?
- ¿Cuándo sería preferible descartar el registro?

Verifique de nuevo la calidad al terminar.

Análisis Exploratorio de Datos (EDA)

Definición

Proceso de examinar y resumir los datos para **comprender su comportamiento, identificar patrones, comparar grupos y detectar valores inusuales.**

¿Qué buscamos?

- Comprender las distribuciones
- Comparar grupos o categorías
- Identificar valores potencialmente atípicos
- Descubrir patrones y relaciones

Qué no es todavía

El EDA no demuestra causalidad ni confirma por sí solo una hipótesis. **Describe, revela patrones y genera nuevas preguntas.**

Explorar no es simplemente generar gráficos: cada resultado debe responder una pregunta sobre los datos.

Las cuatro miradas del EDA

Mirada	Pregunta	Instrumento
Distribución	¿Cómo se reparten los valores?	Histograma
Tendencia central y dispersión	¿Cuál es el valor típico y cuánto varía?	Media, mediana, desviación
Agrupaciones	¿Se comportan igual todos los grupos?	groupby, barras
Valores extremos	¿Hay registros que dominan el resultado?	Boxplot, máximos

Regla: cuando media y mediana difieren mucho, la media deja de representar al conjunto.

¿Qué nos dicen los datos sobre las ventas?

Laboratorio 4 · 45 min

Propósito

Explorar el comportamiento de las transacciones de Andina Retail mediante medidas descriptivas, agrupaciones y visualizaciones.

Ruta del laboratorio

1. Valor típico y dispersión
2. Comparación entre grupos
3. Distribución de las ventas
4. Valores potencialmente atípicos
5. Conclusiones basadas en evidencia

Cada cálculo y cada gráfico deben responder una pregunta analítica.

Paso 1 · ¿Cuál es el valor típico de una transacción?

Laboratorio 4 · 45 min

```
df["ventas"].describe()
```

```
df["ventas"].mean()
```

```
df["ventas"].median()
```

```
df["ventas"].std()
```

Interprete

- ¿Cuál es el valor medio de una transacción?
- ¿Cuál es el valor mediano?
- ¿Media y mediana son similares?
- ¿Qué indica la dispersión observada?

La media y la mediana resumen el centro de la distribución, pero no necesariamente cuentan la misma historia.

Paso 2 · ¿Cómo cambian las ventas entre grupos?

Laboratorio 4 · 45 min

```
ventas_ciudad = (  
    df.groupby("ciudad")["ventas"]  
        .agg(["count", "mean", "sum"])  
        .sort_values("sum", ascending=False)  
)
```

```
ventas_categoria = (  
    df.groupby("categoria")["ventas"]  
        .agg(["count", "mean", "sum"])  
        .sort_values("sum", ascending=False)  
)
```

```
ventas_ciudad  
ventas_categoria
```

Interprete

- ¿Qué ciudad concentra mayor valor vendido?
- ¿Qué categoría concentra mayor valor vendido?
- ¿Mayor número de transacciones implica mayor facturación?
- ¿Qué aporta comparar count, mean y sum?

Paso 3 · ¿Cómo se distribuye el valor de las transacciones?

Laboratorio 4 · 45 min

```
import matplotlib.pyplot as plt

df["ventas"].plot(
    kind="hist",
    bins=40
)

plt.xlabel("Valor de la transaccion")
plt.ylabel("Frecuencia")
plt.show()
```

Interprete

- ¿Dónde se concentra la mayoría de las transacciones?
- ¿La distribución parece simétrica?
- ¿Existe una cola hacia valores elevados?
- ¿Esto ayuda a explicar diferencias entre media y mediana?

Paso 4 · ¿Dónde se concentra el valor vendido?

Laboratorio 4 · 45 min

```
ventas_por_ciudad = (  
    df.groupby("ciudad")["ventas"]  
        .sum()  
        .sort_values(ascending=False)  
)  
  
ventas_por_ciudad.plot(kind="bar")  
  
plt.ylabel("Valor total de ventas")  
plt.xlabel("Ciudad")  
plt.show()
```

Interprete

- ¿Qué ciudad presenta el mayor valor vendido?
- ¿Las diferencias son grandes o pequeñas?
- ¿El gráfico confirma el resultado del `groupby()`?
- ¿Qué información comunica mejor el gráfico?

```
df.boxplot(column="ventas")  
plt.ylabel("Valor de la transaccion")  
plt.show()
```

```
cols = ["fecha", "producto",  
        "ciudad", "categoria",  
        "unidades", "ventas"]
```

```
df.nlargest(5, "ventas")[cols]
```

Interprete

- ¿Aparecen valores alejados del resto?
- ¿Qué transacciones presentan los valores más altos?
- ¿Son necesariamente errores?
- ¿Tenemos evidencia suficiente para eliminarlos?

Un valor atípico estadísticamente no es necesariamente un dato incorrecto.

Entregable

Formule entre tres y cinco conclusiones sobre las transacciones de Andina Retail. Cada afirmación debe estar respaldada por un resultado obtenido durante el análisis.

Debe poder responder

- ¿Cuál es el valor típico de una transacción?
- ¿Dónde se concentra el valor vendido?
- ¿Cómo se distribuyen las transacciones?
- ¿Existen valores potencialmente atípicos?

Criterio de evaluación

Se evalúa la **interpretación de la evidencia**, no únicamente la ejecución del código.

Ejecutar código no equivale a realizar analítica de datos.

¿Dónde estamos dentro de CRISP-DM?

Etapas recorridas hoy

- **Business Understanding:** problema, preguntas y criterio de éxito
- **Data Understanding:** perfilado y registro de hallazgos
- **Data Preparation:** tipos, categorías, faltantes y duplicados

Próxima sesión

- EDA en profundidad y relaciones entre variables
- Tratamiento formal de valores atípicos
- Preparación para la etapa de modelado

Traer

Cuaderno ejecutado y las cinco líneas de conclusión.

Problema → datos → preguntas → análisis → evidencia → decisión.