
Analítica de Datos

Sesión 02. Del EDA a la detección de patrones

Estadística descriptiva aplicada, valores atípicos
y relaciones entre variables

Luis Miguel Gómez Meneses

Universidad Cooperativa de Colombia

Ingeniería de Software — Séptimo semestre

Cómo trabajaremos hoy

Bloque	Contenido	Tiempo
Continuidad	Cierre de preparación de datos y EDA inicial	45 min
Teoría 1	Estadística descriptiva aplicada	30 min
Lab 5	Descripción de una variable	25 min
Teoría 2	Valores atípicos y criterio IQR	20 min
Lab 6	Detección e investigación de valores atípicos	20 min
Teoría 3	Relaciones entre variables y patrones iniciales	20 min
Lab 7	Exploración de patrones	15 min

Continuaremos trabajando con el dataset de Andina Retail.

¿Qué sabemos hasta ahora de las ventas?

PUNTO DE PARTIDA

En el Laboratorio 4 utilizamos medidas y gráficos para comenzar a describir el comportamiento de las transacciones de Andina Retail.

Ya observamos

- media y mediana;
- desviación estándar;
- distribución de las ventas;
- diferencias entre grupos;
- posibles valores atípicos.

Ahora queremos profundizar

¿Son suficientes estos resultados para describir adecuadamente una variable?

¿Qué información aporta cada medida sobre **posición, dispersión y forma**?

El EDA no consiste en calcular más estadísticas, sino en elegir cuáles ayudan a comprender el comportamiento de los datos.

¿Qué significa describir una variable?

ESTADÍSTICA DESCRIPTIVA APLICADA

Un único estadístico no resume todo el comportamiento de una variable. En el EDA debemos observarla desde diferentes perspectivas.

Posición

¿Dónde se encuentran los datos?

- Media
- Mediana
- Cuartiles

Dispersión

¿Qué tan separados están?

- Rango
- Desviación estándar
- Rango intercuartílico

Forma

¿Cómo se distribuyen?

- Simetría
- Asimetría
- Valores extremos

Dos conjuntos pueden tener la misma media y, aun así, presentar comportamientos completamente diferentes.

La media no cuenta toda la historia

POSICIÓN Y DISPERSIÓN

Considere dos conjuntos que representan el valor de cinco transacciones:

Conjunto A

90 95 100 105 110

Media = 100

Los valores se encuentran relativamente **cerca del centro.**

Conjunto B

20 60 100 140 180

Media = 100

Los valores se encuentran mucho más **separados del centro.**

Si ambos conjuntos tienen media 100, ¿podemos afirmar que presentan el mismo comportamiento?

¿Qué es la dispersión?

POSICIÓN Y DISPERSIÓN

La respuesta a la pregunta anterior es **no**.

Aunque los dos conjuntos tienen la misma media, sus valores presentan diferente grado de separación.

Dispersión

La **dispersión** describe qué tanto varían los datos y qué tan alejados se encuentran entre sí o respecto a un valor central.



¿Cómo podemos medir esa dispersión?

¿Cómo medimos la dispersión?

MEDIDAS DE DISPERSIÓN

Existen diferentes medidas para cuantificar la variabilidad de una variable. Cada una describe la dispersión desde una perspectiva diferente.

Rango

Diferencia entre el valor máximo y el mínimo.

$$R = x_{\text{máx}} - x_{\text{mín}}$$

Utiliza los extremos de la distribución.

Desviación estándar

Indica cuánto se alejan, en general, los valores respecto a la media.

Se expresa en las mismas unidades que la variable.

Rango intercuartílico

Mide la dispersión del 50 % central de los datos.

$$IQR = Q_3 - Q_1$$

Es menos sensible a valores extremos.

La elección de una medida de dispersión depende del comportamiento de los datos.

Rango: la amplitud total de los datos

MEDIDAS DE DISPERSIÓN

El **rango** es la medida de dispersión más sencilla: compara directamente los valores extremos de una variable.

$$R = x_{\text{máx}} - x_{\text{mín}}$$

Ejemplo

Si el valor mínimo de una transacción es \$20.000 y el máximo es \$500.000:

$$R = 500.000 - 20.000 = 480.000$$

Las transacciones abarcan un intervalo de \$480.000.

¿El rango describe toda la dispersión?

MEDIDAS DE DISPERSIÓN

El rango es fácil de interpretar, pero utiliza solamente **dos observaciones** del conjunto:

el valor mínimo



el valor máximo

Limitación

Un único valor extremadamente alto o bajo puede modificar considerablemente el rango, aunque el resto de las observaciones permanezca prácticamente igual.

¿Cómo podemos medir la variabilidad utilizando todas las observaciones y no solamente los extremos?

Desviación estándar: considerar todos los datos


MEDIDAS DE DISPERSIÓN

A diferencia del rango, la desviación estándar utiliza **todas las observaciones** del conjunto.

Idea central

Para cada observación podemos preguntarnos:

¿Qué tan lejos se encuentra este valor de la media?



Cuanto mayores sean esas diferencias, mayor será la variabilidad de los datos.

De las distancias a la desviación estándar

MEDIDAS DE DISPERSIÓN

Para una muestra, la desviación estándar puede expresarse como:

$$s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}$$

¿Qué representa?

- x_i : cada observación.
- $\bar{x}$: media de la muestra.
- $x_i - \bar{x}$: distancia respecto a la media.

¿Cómo interpretarla?

- s pequeña: menor variabilidad.
- s grande: mayor variabilidad.
- Conserva las unidades de la variable.

¿Qué ocurre cuando existen valores extremos?

MEDIDAS DE DISPERSIÓN

Considere estas cinco transacciones:

90 95 100 105 **500**

Observe

Cuatro valores se encuentran relativamente próximos entre sí, mientras que la observación de **500** se encuentra considerablemente alejada del resto.

¿Qué efecto tendrá esta observación sobre la media y la desviación estándar?

Sensibilidad a valores extremos

MEDIDAS DE DISPERSIÓN

Un valor muy alejado del resto puede modificar las medidas que dependen directamente de la media.

Media

El valor extremo puede **desplazar la media** hacia valores más altos o más bajos.

Desviación estándar

Una mayor distancia respecto a la media puede producir una **mayor desviación estándar**.

Entonces...

Necesitamos una medida de dispersión que sea **menos sensible a los valores extremos**.

¿Qué ocurre si nos concentramos únicamente en la mitad central de los datos?

Cuartiles: dividir la distribución

MEDIDAS DE DISPERSIÓN

Una vez ordenados los datos, los **cuartiles** permiten dividir la distribución en cuatro partes.




Interpretación

- Q_1 : aproximadamente el 25 % de los datos queda por debajo.
- Q_2 : corresponde a la **mediana**.
- Q_3 : aproximadamente el 75 % de los datos queda por debajo.

Rango intercuartílico: el 50 % central

MEDIDAS DE DISPERSIÓN

El **rango intercuartílico (IQR)** mide la amplitud ocupada por la mitad central de las observaciones.



$$IQR = Q_3 - Q_1$$

Ventaja

Al concentrarse en la mitad central de los datos, el IQR es **menos sensible a observaciones extremas** que el rango y la desviación estándar.

Cuartiles e IQR: ¿cuál es la diferencia?

MEDIDAS DE DISPERSIÓN

Supongamos que, después de ordenar los valores de una variable, obtenemos:

$$Q_1 = 100 \qquad Q_2 = 180 \qquad Q_3 = 300$$

Los cuartiles son posiciones

Q_1 , Q_2 y Q_3 son puntos que permiten dividir los datos ordenados en cuatro partes.

Q_2 corresponde a la mediana.

El IQR es una medida

Utiliza dos de esos puntos para medir la amplitud del 50 % central:

$$IQR = Q_3 - Q_1$$

$$IQR = 300 - 100 = 200$$

Los cuartiles dividen la distribución; el IQR mide qué tan disperso está su 50 % central.

APLICACIÓN CON ANDINA RETAIL

Aplicaremos las medidas estudiadas para profundizar en el comportamiento de la variable ventas.

Analizaremos

- media y mediana;
- rango;
- desviación estándar;
- cuartiles;
- rango intercuartílico (IQR).

Pregunta central


¿Qué información adicional obtenemos cuando estudiamos conjuntamente la **posición** y la **dispersión** de una variable?

Continuaremos trabajando con el conjunto de datos preparado de Andina Retail.

Del IQR a los valores potencialmente atípicos

DE LA DISPERSIÓN A LA DETECCIÓN

El IQR nos proporciona una referencia de cuánto se dispersa el 50 % central de los datos.



La nueva pregunta

Si conocemos la dispersión de la zona central, podemos preguntarnos:

¿Cuándo una observación está suficientemente alejada para considerarla potencialmente atípica?

Criterio del rango intercuartílico

DETECCIÓN DE VALORES POTENCIALMENTE ATÍPICOS

Una regla ampliamente utilizada define dos límites a partir de los cuartiles y del IQR.

Límite inferior

$$L_i = Q_1 - 1.5(IQR)$$

Una observación menor que este límite se considera **potencialmente atípica**.

Límite superior

$$L_s = Q_3 + 1.5(IQR)$$

Una observación mayor que este límite se considera **potencialmente atípica**.

Importante

Superar estos límites no demuestra que una observación sea incorrecta. El criterio únicamente la identifica como **inusual respecto a la distribución**.

Ejemplo: del IQR a los límites

DETECCIÓN DE VALORES POTENCIALMENTE ATÍPICOS

Considere los siguientes datos ordenados:

1, 1, 6, **13**, 13, 14, 14, **14**, 15, 15, 16, **18**, 18, 18, 19

$$Q_1 = 13 \quad Q_2 = 14 \quad Q_3 = 18$$

$$IQR = Q_3 - Q_1 = 18 - 13 = 5$$

Límite inferior

$$13 - 1.5(5) = 5.5$$

Atípicos potenciales:

$$x < 5.5$$

Límite superior

$$18 + 1.5(5) = 25.5$$


Atípicos potenciales:

$$x > 25.5$$

¿Cómo se representa esta información?

DIAGRAMA DE CAJA Y BIGOTES

El boxplot resume visualmente la posición, dispersión y observaciones potencialmente atípicas.



Lectura

La **caja** representa el 50 % central (Q_1 a Q_3); la línea naranja es la **mediana**. Los bigotes llegan hasta las observaciones no atípicas más extremas.

APLICACIÓN CON ANDINA RETAIL

Aplicaremos el criterio del rango intercuartílico para identificar observaciones potencialmente atípicas en la variable ventas.

Aplicaremos

- cálculo de Q_1 , Q_3 e IQR;
- límites inferior y superior;
- identificación de valores atípicos;
- representación mediante boxplot.

Pregunta central

¿Una observación identificada estadísticamente como atípica debe considerarse automáticamente un dato incorrecto?

Detectar un valor atípico es el inicio de la investigación, no el final del análisis.

De una variable a la relación entre variables

ANÁLISIS BIVARIADO

Hasta ahora hemos estudiado características de las variables **individualmente**:



Pero muchas preguntas analíticas requieren estudiar **dos variables conjuntamente**.

Nueva pregunta

¿Existe alguna relación entre las características de una transacción y el valor de sus ventas?

unidades $\longleftrightarrow$ ventas

categoría $\longleftrightarrow$ ventas

¿Qué cambia cuando analizamos dos variables?

ANÁLISIS BIVARIADO

En el análisis **univariado** estudiamos una variable de manera individual.

En el análisis **bivariado** estudiamos dos variables conjuntamente para explorar si existe algún patrón o relación entre ellas.



Cambio de perspectiva

Pasamos de preguntar **cómo se comporta una variable** a preguntar **cómo se comportan dos variables conjuntamente**.

¿Qué podemos preguntar al estudiar dos variables?

ANÁLISIS BIVARIADO

Consideremos nuevamente:

unidades $\longleftrightarrow$ ventas

Preguntas

- ¿cambian conjuntamente?
- ¿existe algún patrón?
- ¿cómo es esa relación?

Lo que buscamos

Identificar si el comportamiento de una variable presenta alguna **relación observable** con el comportamiento de otra.

Importante

Encontrar una relación entre dos variables **no demuestra que una sea la causa de la otra.**

Relación no implica causalidad

UNA DISTINCIÓN FUNDAMENTAL

Encontrar que dos variables presentan una **relación estadística** no significa que una produzca cambios en la otra.

Relación o asociación

Dos variables presentan algún comportamiento conjunto observable en los datos.

$$X \longleftrightarrow Y$$

Causalidad

Un cambio en una variable produce, directa o indirectamente, un cambio en otra.

$$X \longrightarrow Y$$

Importante

Una asociación observada puede generar una **hipótesis causal**, pero por sí sola **no demuestra causalidad**.

¿Todas las relaciones se estudian de la misma manera?

TIPOS DE VARIABLES

La forma de explorar una relación depende del **tipo de variables** que estamos comparando.

Numérica – numérica

Estudiamos cómo cambian conjuntamente dos variables cuantitativas.

$\text{unidades} \longleftrightarrow \text{ventas}$

Podemos explorar:

- dirección de la relación;
- intensidad;
- forma o patrón.

Categorica – numérica

Comparamos el comportamiento de una variable cuantitativa entre diferentes grupos.

$\text{categoria} \longleftrightarrow \text{ventas}$


Podemos explorar:

- diferencias entre grupos;
- posición;
- dispersión.

¿Cómo observamos la relación entre dos variables numéricas?

DIAGRAMA DE DISPERSIÓN

Un **diagrama de dispersión** representa cada observación mediante un punto definido por los valores de dos variables numéricas.



¿Qué buscamos?

La disposición de los puntos permite explorar si existe un **patrón**, su **dirección** y qué tan claramente se manifiesta la relación.

¿Qué patrones podemos observar?

RELACIONES ENTRE VARIABLES NUMÉRICAS

La disposición de los puntos permite identificar visualmente la **dirección** de una posible relación.



La dirección puede observarse visualmente. El siguiente paso será medir qué tan marcada es la relación.

¿Cómo cuantificamos una relación?

CORRELACIÓN

El diagrama de dispersión permite **observar** cómo se comportan conjuntamente dos variables numéricas.

Pero la inspección visual no nos proporciona por sí sola una medida de **qué tan marcada es la relación lineal**.



Buscamos responder

- ¿Cuál es la **dirección** de la relación?
- ¿Qué tan **intensa** es la relación lineal?

Una de las medidas más utilizadas es el **coeficiente de correlación de Pearson**.

Coeficiente de correlación de Pearson

CORRELACIÓN LINEAL

El **coeficiente de correlación de Pearson**, representado por r , cuantifica la **dirección** y la **intensidad** de la relación lineal entre dos variables numéricas.

$$-1 \leq r \leq 1$$

**Relación lineal
negativa perfecta**

**Sin relación
lineal**

**Relación lineal
positiva perfecta**



Cuanto más se aproxima r a -1 o 1 , más marcada es la **relación lineal**.

¿Cómo interpretamos el valor de r ?

SIGNO E INTENSIDAD

Para interpretar una correlación observamos dos características diferentes del coeficiente.

1. El signo

Indica la **dirección** de la relación.

$$r > 0 \implies \text{positiva}$$

$$r < 0 \implies \text{negativa}$$

2. La magnitud

Indica qué tan **marcada** es la relación lineal.

$$|r| \rightarrow 1 \implies \text{más intensa}$$

$$|r| \rightarrow 0 \implies \text{más débil}$$

El signo indica la dirección; la magnitud indica qué tan marcada es la relación lineal.

¿Qué nos dicen distintos valores de r ?

INTERPRETACIÓN DE LA CORRELACIÓN

Compare los siguientes coeficientes de correlación:

Valor	Dirección	Lectura
$r = 0.90$	Positiva	Relación lineal marcada
$r = 0.35$	Positiva	Relación lineal menos marcada
$r = -0.80$	Negativa	Relación lineal marcada
$r = 0.05$	Positiva	Relación lineal muy débil

Observe

$r = 0.90$ y $r = -0.80$ tienen signos diferentes, pero ambos presentan una **magnitud elevada**.

Una correlación sorprendente


INTERPRETACIÓN DE UNA RELACIÓN

Considere la relación observada entre:

Consumo de mantequilla per cápita en EE. UU.

frente a

Generación de energía eólica en Lituania



Correlación no implica causalidad

INTERPRETAR CON CUIDADO

Dos variables pueden presentar una **relación estadística marcada** sin que una sea responsable de los cambios en la otra.

Correlación $\nRightarrow$ Causalidad

En el ejemplo anterior

El consumo de mantequilla en EE. UU. y la generación de energía eólica en Lituania pueden mostrar un comportamiento conjunto marcado.

Esto **no demuestra** que los cambios en una variable sean responsables de los cambios en la otra.

Asociación y causalidad no son lo mismo

INTERPRETACIÓN DE RELACIONES

Correlación

Describe una **asociación** entre dos variables.

$$X \longleftrightarrow Y$$

Permite estudiar cómo varían conjuntamente.

Causalidad

Implica que cambios en una variable **producen cambios** en otra.

$$X \longrightarrow Y$$

Requiere evidencia adicional y un diseño adecuado.

Una correlación, incluso si es elevada, **no constituye por sí sola evidencia causal**.

¿Qué ocurre si una variable es categórica?

RELACIONES ENTRE VARIABLES

No todas las relaciones involucran dos variables numéricas.

También podemos estudiar cómo se comporta una **variable numérica** entre diferentes grupos definidos por una **variable categórica**.



La pregunta cambia


En lugar de preguntar si ambas variables aumentan o disminuyen conjuntamente, preguntamos:

¿Cómo cambia la distribución de las ventas entre categorías?

¿Cómo representamos la comparación entre grupos?

BOXPLOTS POR CATEGORÍA

El boxplot permite comparar visualmente las **distribuciones** de una variable numérica entre varios grupos.



Compare la **mediana**, la **dispersión** y los **valores atípicos** de cada grupo.

Laboratorio 7 — Exploración de relaciones y patrones

APLICACIÓN

Volvamos al conjunto de datos preparado de **Andina Retail**.

Aplicaremos dos formas de análisis bivariado:

Númerica – númerica

unidades $\longleftrightarrow$ ventas

Categorica – númerica

categoría $\longleftrightarrow$ ventas

Pregunta central

¿Qué información adicional obtenemos cuando analizamos **dos variables conjuntamente**?