
Analítica de Datos

Clases 6 y 7. ANOVA y regresión logística

Comparación de medias y clasificación binaria,
interpretación de resultados y evaluación de modelos

Luis Miguel Gómez Meneses

Universidad Cooperativa de Colombia

Ingeniería de Software — Séptimo semestre

Cómo trabajaremos hoy

Bloque	Contenido	Tiempo
Continuidad	Dudas de regresión múltiple y laboratorios anteriores	15 min
Teoría 1	ANOVA: medias, hipótesis, estadístico F y supuestos	45 min
Lab 15	Comparación de medias e interpretación del valor p	45 min
Descanso	Pausa	10 min
Teoría 2	Regresión logística: probabilidades y clases 0/1	45 min
Lab 16	Modelo, matriz de confusión y métricas de clasificación	65 min
Cierre	Interpretación de resultados y conclusiones	15 min
Total	Sesión integrada: clases 6 y 7	240 min

Cada tema combina explicación y aplicación en Google Colab.

Conexión con la clase anterior

Lo que ya trabajamos

Con la **regresión lineal**, usamos una o varias variables para predecir una cantidad numérica.

Hoy trabajaremos con las flores del dataset Iris

- **ANOVA: comparar medias.**

¿El ancho medio del sépalo difiere entre las especies?

- **Regresión logística: clasificación binaria.**

Dado el ancho del sépalo, ¿cuál es la probabilidad de que una flor sea setosa?
Etiquetas: setosa (1) y otras especies (0).

Usaremos las mismas flores y mediciones en ambos laboratorios.

ANOVA con las tres especies de Iris

La pregunta del análisis

El **análisis de varianza (ANOVA)** contrasta si las medias poblacionales de los grupos son iguales. Compararemos el **ancho del sépalo** entre especies.

Factor: especie de flor. **Respuesta:** ancho del sépalo (cm).

Especie	Flores	Media muestral (cm)
<i>Iris setosa</i>	50	3,428
<i>Iris versicolor</i>	50	2,770
<i>Iris virginica</i>	50	2,974

¿Estas diferencias aportan evidencia de medias poblacionales distintas?

También debemos considerar la variabilidad de cada grupo.

¿Qué es el dataset Iris?

Una tabla con mediciones de flores

Iris contiene **150 observaciones**: 50 de *setosa*, 50 de *versicolor* y 50 de *virginica*. **Cada fila representa una flor.**

Columna	Tipo de dato	Unidad
Longitud del sépalo	Numérico	cm
Ancho del sépalo	Numérico	cm
Longitud del pétalo	Numérico	cm
Ancho del pétalo	Numérico	cm
Especie	Categorico	—

Hoy nos concentraremos en el ancho del sépalo y la especie.

Iris se utiliza para practicar análisis estadístico y modelos de clasificación.

¿Cómo leeremos y utilizaremos Iris?

Ejemplo real: una fila del dataset. Las cuatro medidas están en centímetros.

Longitud del sépalo	Ancho del sépalo	Longitud del pétalo	Ancho del pétalo	Especie
5,1	3,5	1,4	0,2	setosa

Laboratorio 15: comparar medias con ANOVA

Grupos: las tres especies.

Variable que comparamos: ancho del sépalo.

Laboratorio 16: clasificar con regresión logística

Entrada del modelo: ancho del sépalo.

Respuesta que queremos predecir: si la flor es setosa.

Codificamos setosa como 1 y las otras especies como 0.

¿Qué hace ANOVA con estos datos?

La pregunta que queremos resolver

Las medias de nuestra muestra son diferentes. **¿Esto aporta evidencia de diferencias reales entre las medias poblacionales de las especies?**

1. **Mide la separación entre las medias.**

Compara los anchos medios de setosa, versicolor y virginica.

2. **Considera la variación dentro de cada especie.**

Las flores de una misma especie tienen anchos diferentes.

3. **Relaciona ambas variaciones.**

Calcula el estadístico F y el valor p para evaluar la evidencia contra la igualdad de medias.

Un resultado significativo indica que al menos una media poblacional difiere. Identificar los pares requiere comparaciones posteriores.

Hipótesis del ANOVA para Iris

Cada μ representa la **media poblacional** del ancho del sépalo para una especie.

Hipótesis nula: H_0

$$H_0 : \mu_{\text{setosa}} = \mu_{\text{versicolor}} = \mu_{\text{virginica}}$$

Las tres especies tienen el mismo ancho medio poblacional del sépalo.

Hipótesis alternativa: H_1

Al menos una media poblacional es diferente.

No es necesario que las tres medias sean distintas entre sí.

Si rechazamos H_0 , las comparaciones posteriores permiten investigar qué pares de especies difieren.

La variabilidad y el estadístico F

Variabilidad entre especies

Mide cuánto se separan las **medias de las especies** respecto a la media general. Comparamos los anchos medios de setosa, versicolor y virginica.

Variabilidad dentro de cada especie

Mide cuánto se aleja el ancho del sépalo de cada flor de la **media de su propia especie**.

Por ejemplo, las flores setosa presentan anchos diferentes.

$$F = \frac{CM_{\text{entre}}}{CM_{\text{dentro}}}$$

CM: cuadrado medio, una medida de variabilidad.

Un F grande indica mayor separación entre medias en relación con la variación interna.

Decisión y supuestos del ANOVA

Fijamos antes del análisis el nivel de significancia: $\alpha = 0,05$.

Decisión a partir del valor p

- Si $p < 0,05$: rechazamos H_0 .

Hay evidencia de que al menos una especie tiene un ancho medio poblacional del sépalo diferente.

- Si $p \geq 0,05$: no rechazamos H_0 .

No hay evidencia suficiente para concluir que las medias poblacionales difieren.

Supuestos del ANOVA clásico de un factor

- **Independencia:** observaciones independientes, según el diseño del muestreo.
- **Normalidad:** distribución aproximadamente normal dentro de cada especie.
- **Varianzas:** dispersión similar entre especies.

No rechazar H_0 no demuestra que las medias sean iguales.

GOOGLE COLAB | TIEMPO ESTIMADO: 45 MINUTOS

Pregunta del laboratorio

¿El ancho medio del sépalo es igual en *setosa*, *versicolor* y *virginica*?

1. **Cargar Iris:** reconocer la especie y el ancho del sépalo (cm).
2. **Explorar:** calcular medias y desviaciones por especie; crear un boxplot.
3. **Revisar los supuestos:** discutir la independencia, la normalidad por grupo y la homogeneidad de varianzas.
4. **Aplicar ANOVA:** formular hipótesis, obtener F y p ; usar $\alpha = 0,05$.
5. **Concluir:** responder la pregunta e indicar los límites del análisis.

Entregable: notebook con tabla descriptiva, boxplot, resultado de ANOVA y conclusión propia.

De ANOVA a regresión logística

MISMO DATASET: IRIS | UNA NUEVA PREGUNTA

ANOVA: comparar medias

¿El ancho medio del sépalo es igual en las tres especies?

Comparamos grupos cuya especie ya conocemos.

Regresión logística: clasificar

Dado el ancho del sépalo de una flor, ¿qué probabilidad tiene de ser *setosa*?

Usamos una medida para predecir una categoría.

Entrada X : ancho del sépalo, en centímetros.

Clase y : 1 = *setosa*; 0 = no *setosa* (*versicolor* o *virginica*).

¿Qué entrega el modelo?

Una probabilidad entre 0 y 1: $P(\text{setosa} \mid \text{ancho del sépalo})$.

Diferencias entre medias no garantizan una clasificación perfecta.

¿Cómo calcula la probabilidad?

REGRESIÓN LOGÍSTICA BINARIA | SETOSA FRENTE A NO SETOSA

1. Combinar la medida

$$z = \beta_0 + \beta_1 x$$

x : ancho del sépalo en cm.

β_0 y β_1 : parámetros aprendidos usando flores etiquetadas.

2. Aplicar la función sigmoide

$$p = P(y = 1 | x) = \frac{1}{1 + e^{-z}}$$

La función sigmoide produce un valor entre 0 y 1.

Aquí, $y = 1$ significa *setosa*.

Ejemplo ilustrativo: el modelo entrega $p = 0,80$

El modelo estima una probabilidad del **80 % de ser *setosa*** y del **20 % de no ser *setosa***.

Un umbral permitirá convertir esta probabilidad en una clase.

De la probabilidad a la clase

Usaremos un umbral de 0,5

Sea p la probabilidad estimada de ser *setosa*:

Si $p \geq 0,5$, predecimos **setosa (1)**.

Si $p < 0,5$, predecimos **no setosa (0)**.

Probabilidad p	Comparación	Clase predicha
0,80	$0,80 \geq 0,5$	<i>setosa</i>
0,60	$0,60 \geq 0,5$	<i>setosa</i>
0,30	$0,30 < 0,5$	no <i>setosa</i>

Pregunta para discutir

Si aumentamos el umbral a 0,7, ¿qué clase asignamos a la flor con $p = 0,60$?

El umbral se puede ajustar. La clase predicha puede diferir de la especie real.

¿Cómo evaluamos la clasificación?

Entrenar y evaluar con datos separados

Entrenamiento (80 %): 120 flores para aprender los parámetros.

Prueba (20 %): 30 flores para evaluar las predicciones.

La **matriz de confusión** compara la clase real con la predicha.

Clase real	Predice setosa (1)	Predice no setosa (0)
Setosa (1)	Verdadero positivo (VP)	Falso negativo (FN)
No setosa (0)	Falso positivo (FP)	Verdadero negativo (VN)

VP y VN: aciertos.

FP y FN: errores.

Pregunta para discutir

Una flor *virginica* se clasifica como *setosa*. ¿Es un falso positivo o un falso negativo?

En este problema, la clase positiva es *setosa* ($y = 1$).

Métricas para evaluar la clasificación

Evaluamos sobre las flores de **prueba**. La clase positiva es *setosa*.

Métrica	Fórmula	¿Qué mide?
Exactitud (accuracy)	$\frac{VP + VN}{N}$	Proporción de flores clasificadas correctamente.
Precisión	$\frac{VP}{VP + FP}$	De las predichas como setosa, ¿qué proporción lo es realmente?
Recall	$\frac{VP}{VP + FN}$	De las setosa reales, ¿qué proporción identificamos?
F1	$\frac{2VP}{2VP + FP + FN}$	Media armónica de precisión y recall.

N : total de flores evaluadas.

¿Basta con la exactitud?

Predecir siempre “no setosa” acierta el 66,7 % en Iris. ¿Qué recall obtiene?

GOOGLE COLAB | TIEMPO ESTIMADO: 65 MINUTOS

Pregunta del laboratorio

¿Qué probabilidad tiene una flor de ser *setosa* según el ancho de su sépalo?

1. **Preparar:** entrada = ancho del sépalo; salida = setosa (1) o no setosa (0).
2. **Separar los datos:** 80 % para entrenamiento y 20 % para prueba, conservando las proporciones de las clases.
3. **Entrenar:** ajustar la regresión logística con las flores de entrenamiento.
4. **Predecir:** obtener probabilidades y asignar clases con un umbral de 0,5.
5. **Evaluar en prueba:** matriz de confusión, exactitud, precisión, recall y F1.

Entregable: notebook con resultados, respuestas a las preguntas y conclusión propia.

Cierre: comparar medias y predecir clases

Laboratorio 15: ANOVA

Comparamos el **ancho medio del sépalo** entre las tres especies.

Encontramos evidencia de que **al menos una media poblacional difiere**. ANOVA no identifica por sí solo cuáles pares difieren.

Laboratorio 16: regresión logística

Estimamos la probabilidad de ser **setosa** y asignamos una clase.

En prueba: **25 de 30 aciertos** (83,3 % de exactitud), pero identificamos **6 de las 10 setosa** (60 % de recall).

Pregunta de cierre

¿Por qué una diferencia entre medias no garantiza una clasificación perfecta?

Para completar: preguntas y conclusión propia en los laboratorios 15 y 16.