Analítica de Datos

Clase 8. Árboles de decisión y validación cruzada

Construcción de modelos de clasificación,
control del sobreajuste y evaluación del desempeño

Luis Miguel Gómez Meneses
Universidad Cooperativa de Colombia
Ingeniería de Software — Séptimo semestre

Cómo trabajaremos hoy

Bloque	Contenido	Tiempo
Continuidad	Repaso de clasificación y regresión logística	15 min
Teoría 1	Árboles de decisión: estructura, reglas y predicción	40 min
Lab 17	Construcción e interpretación de un árbol	55 min
Descanso	Pausa	10 min
Teoría 2	Sobreajuste, complejidad y validación cruzada	45 min
Lab 18	Evaluación mediante validación cruzada	60 min
Cierre	Interpretación de resultados y conclusiones	15 min
Total	**Clase 8: teoría y dos laboratorios**	**240 min**

Cada tema combina explicación y aplicación en Google Colab.

De la regresión logística al árbol de decisión

Lo que ya trabajamos

Con la **regresión logística binaria**, estimamos una probabilidad y usamos un umbral para asignar una clase.

La idea de hoy

Un árbol clasifica mediante **preguntas sucesivas sobre las características** de una observación.

Ejemplo de pregunta

¿El ancho del pétalo es menor o igual a cierto valor? La respuesta determina qué camino seguir.

¿Cómo tomaríamos una decisión paso a paso?

¿Cómo está formado un árbol de decisión?

Una secuencia de preguntas

Un árbol divide las observaciones mediante reglas, hasta asignar una predicción.

Elemento	Función
Nodo raíz	Nodo inicial del árbol.
Nodo interno	Contiene una regla que divide los datos.
Rama	Camino asociado a una respuesta.
Hoja	Nodo final que asigna una predicción.

Recorrido de una observación

Comienza en la raíz, sigue las ramas según sus características y termina en una hoja.

De dos clases a tres especies

Clase anterior: clasificación binaria

Predecíamos **setosa o no setosa**. Versicolor y virginica se agrupaban como “no setosa”.

Hoy: clasificación multiclase

Predeciremos una de las tres especies: **setosa, versicolor o virginica**.

Cada flor pertenece a una sola clase.

Si una flor no es setosa, ¿ya sabemos cuál de las otras dos especies es?

Multiclase significa tres o más clases posibles. Cada predicción asignará una única especie.

¿Cómo clasifica una nueva observación?

EJEMPLO ILUSTRATIVO CON IRIS

Reglas de un árbol simplificado

1. Si la longitud del pétalo es $\leq 2{,}5$ cm: predecir *setosa*.

2. En caso contrario, revisar el ancho del pétalo:

- $\leq 1{,}75$ cm: predecir *versicolor*.
- $> 1{,}75$ cm: predecir *virginica*.

Una nueva flor

Longitud del pétalo: **4,8 cm**. Ancho: **1,5 cm**.

¿Qué camino sigue y qué especie predice?

Las reglas son ilustrativas y pueden cometer errores.

¿Cómo elige el árbol sus preguntas?

Objetivo de cada división

Formar grupos con **menor mezcla de clases**, usando únicamente los datos de entrenamiento.

1. **Probar:** comparar variables y umbrales.
2. **Evaluar:** medir la mezcla en los grupos, considerando sus tamaños.
3. **Elegir:** seleccionar la división permitida que más reduzca esa mezcla.
4. **Repetir:** continuar hasta cumplir un criterio de parada.

Pregunta para discutir

¿Cuál es más puro: un grupo con una sola especie o uno con tres especies mezcladas?

¿Qué significa la impureza de un grupo?

Impureza: mezcla de clases

Un grupo es **puro** si todas sus observaciones pertenecen a la misma clase.

Grupo de 10 flores	Interpretación
10 setosa	Puro: una sola clase.
9 setosa y 1 versicolor	Poca impureza.
5 setosa y 5 versicolor	Máxima impureza para dos clases.

Pureza y generalización

Hojas puras en entrenamiento no garantizan acertar con flores nuevas. Un árbol demasiado complejo puede sobreajustarse.

¿Qué clase predice una hoja?

La clase más frecuente

El árbol predice la **clase más frecuente** entre las observaciones de entrenamiento de esa hoja.

Especie	Flores	Proporción
Setosa	0	$0\,\%$
Versicolor	8	$80\,\%$
Virginica	2	$20\,\%$

Predicción para una nueva flor

Si llega a esta hoja, se predice **versicolor**, con probabilidad estimada $8/10 = 0{,}80$.

Esta proporción no garantiza acertar con una flor nueva.

¿Qué datos recibirá nuestro árbol?

Entradas: las características de cada flor

Usaremos las cuatro medidas de Iris, en centímetros:

- Longitud y ancho del sépalo.
- Longitud y ancho del pétalo.

Salida: la especie que queremos predecir

Setosa, versicolor o virginica.

La especie es la etiqueta de entrenamiento; no se incluye entre las variables de entrada.

¿Por qué sería un error incluir la especie entre las entradas del modelo?

Para clasificar una flor nueva, el árbol utiliza sus medidas sin conocer su especie real.

Aprender y evaluar con flores diferentes

Dividimos las 150 flores de Iris

Entrenamiento: 80 %, equivalente a 120 flores. Se usan para aprender las reglas del árbol.

Prueba: 20 %, equivalente a 30 flores. Se reservan para evaluar el modelo.

Conservamos las proporciones de las especies

La división será **estratificada**: 40 flores de cada especie en entrenamiento y 10 de cada especie en prueba.

¿Por qué acertar con las flores de entrenamiento no demuestra que el árbol funcione con flores nuevas?

Usaremos una semilla fija para reproducir la división. Los datos de prueba no se utilizan para elegir las reglas.

¿Cómo evaluamos las tres clases?

Matriz de confusión

Las **filas** representan la especie real y las **columnas**, la especie predicha. Los aciertos aparecen en la diagonal.

Ejemplo ilustrativo: 30 flores de prueba

Real / Predicha	Setosa	Versicolor	Virginica
Setosa	**10**	0	0
Versicolor	0	**8**	2
Virginica	0	1	**9**

Lectura del resultado

Aciertos: $10 + 8 + 9 = 27$. Exactitud: $27/30 = 0{,}90$, es decir, 90 %.

¿Cuántas versicolor se confundieron con virginica?

Árboles para clasificación y regresión

Árbol de clasificación

Predice una **categoría**.

Ejemplo: identificar una flor como setosa, versicolor o virginica.

Árbol de regresión

Predice una **cantidad numérica**.

Ejemplo: estimar el precio de una vivienda. En su versión estándar, cada hoja predice el promedio de los valores de entrenamiento de esa hoja.

Regresión no significa necesariamente regresión lineal.

El árbol divide los datos mediante reglas. La regresión lineal ajusta una función lineal de los predictores.

¿Hasta dónde puede crecer un árbol?

Profundidad del árbol

Es el mayor número de ramas recorridas desde la raíz hasta una hoja.

La raíz tiene profundidad 0. Un árbol de profundidad 2 realiza como máximo dos preguntas en cada recorrido.

Criterios para detener el crecimiento

- Alcanzar la profundidad máxima permitida.
- No tener suficientes observaciones para dividir.
- No encontrar una división válida que mejore el nodo.

¿Un árbol más profundo siempre predecirá mejor?

Complejidad: encontrar un equilibrio

Dos extremos

Subajuste: el árbol es demasiado sencillo para capturar los patrones.

Sobreajuste: aprende detalles del entrenamiento que no se mantienen en datos nuevos.

¿Cómo controlamos su complejidad?

- Limitar la profundidad máxima.
- Exigir un mínimo de observaciones por hoja.
- Aplicar poda: eliminar ramas de un árbol ya construido.

Elegimos estos ajustes mediante validación. Un buen resultado en entrenamiento no basta.

Ventajas y limitaciones de los árboles

Ventajas

- Los árboles pequeños permiten interpretar sus reglas.
- Capturan relaciones no lineales entre variables.
- Generalmente no requieren estandarizar las entradas.

Limitaciones

- Pueden sobreajustarse si crecen demasiado.
- Pequeños cambios en los datos pueden cambiar sus reglas.
- Los árboles grandes son difíciles de interpretar.

¿Preferiríamos siempre el árbol con más ramas?

Laboratorio 17: clasificar las especies de Iris

GOOGLE COLAB | TIEMPO ESTIMADO: 55 MINUTOS

Pregunta del laboratorio

¿Cómo utiliza un árbol las medidas de una flor para predecir su especie?

1. **Preparar:** cuatro medidas como entradas y especie como salida.
2. **Separar:** 120 flores para entrenamiento y 30 para prueba, mediante división estratificada.
3. **Entrenar:** construir un árbol con profundidad máxima de 3.
4. **Interpretar:** visualizar el árbol y explicar una ruta hasta una hoja.
5. **Evaluar:** obtener la matriz de confusión y la exactitud en prueba.

Entregable: notebook ejecutado, respuestas a las preguntas y conclusión propia.

¿Basta con una sola división de los datos?

Lo que obtuvimos en el laboratorio

El árbol clasificó correctamente **29 de las 30 flores de prueba**: una exactitud del 96,67 %.

Una pregunta pendiente

Si cambiamos las flores utilizadas para entrenar y evaluar, ¿obtendremos el mismo resultado?

La idea de la validación cruzada

Entrenar y evaluar el modelo en varias particiones para observar su **desempeño promedio** y cuánto varía entre ellas.

Una semilla fija permite reproducir una división, pero no demuestra que el resultado sea estable.

Validación cruzada: cinco pliegues

Dividimos el conjunto de entrenamiento

Repartimos las 120 flores de entrenamiento en **cinco grupos de 24 flores**. Las 30 flores de prueba permanecen aparte.

1. Entrenamos con cuatro grupos: **96 flores**.
2. Validamos con el grupo restante: **24 flores**.
3. Repetimos cinco veces, cambiando el grupo utilizado para validar.
4. Resumimos las cinco puntuaciones mediante su promedio y su variación.

En cada ronda se entrena un árbol desde cero, con la misma configuración. Cada flor se usa una vez para validar.

¿Qué grupo valida en cada ronda?

Ronda	Grupo 1	Grupo 2	Grupo 3	Grupo 4	Grupo 5
1	**V**	E	E	E	E
2	E	**V**	E	E	E
3	E	E	**V**	E	E
4	E	E	E	**V**	E
5	E	E	E	E	**V**

E: entrenamiento. **V: validación.**

Cinco evaluaciones

Cada ronda genera una puntuación usando flores que ese árbol no utilizó para entrenarse.

Los grupos se mantienen fijos durante las cinco rondas: cambia cuál se reserva para validar.

¿Cómo interpretamos las cinco puntuaciones?

EJEMPLO ILUSTRATIVO: 24 FLORES POR RONDA

Ronda	1	2	3	4	5
Aciertos	23	22	24	23	22
Exactitud	95,83 %	91,67 %	100 %	95,83 %	91,67 %

Promedio: desempeño observado

La exactitud media es **95 %**. Resume el resultado de las cinco rondas.

Variación: estabilidad entre rondas

La desviación estándar indica cuánto se dispersan las puntuaciones alrededor del promedio. Un valor menor indica resultados más parecidos.

El promedio no garantiza ese mismo resultado con datos nuevos.

Conservar las clases en cada pliegue

¿Qué significa estratificar?

Formar los pliegues conservando, aproximadamente, la **proporción de cada clase**. Así, cada ronda incluye las tres especies.

En nuestras 120 flores de entrenamiento

Tenemos 40 flores de cada especie.

En cada ronda:

- **Validación:** 8 de cada especie, para un total de 24.
- **Entrenamiento:** 32 de cada especie, para un total de 96.

¿Qué dificultad tendríamos si un pliegue no incluyera ninguna flor virginica?

Usaremos cinco pliegues estratificados, con mezcla aleatoria y una semilla fija.

¿Cómo elegimos la profundidad del árbol?

Comparamos distintas configuraciones

Probaremos árboles con profundidad máxima de **1, 2, 3 y 4**, y un árbol **sin límite de profundidad**.

1. Evaluar cada configuración con los **mismos cinco pliegues**.
2. Comparar la exactitud media y la variación entre rondas.
3. Seleccionar la mayor exactitud media; en caso de empate, preferir el árbol más sencillo.
4. Entrenar la configuración elegida con las 120 flores de entrenamiento.

Las 30 flores de prueba se reservan para la evaluación final; no se usan para elegir la profundidad.

Laboratorio 18: comparar árboles de decisión

GOOGLE COLAB | TIEMPO ESTIMADO: 60 MINUTOS

Pregunta del laboratorio

¿Cómo cambia el desempeño del árbol al modificar su profundidad máxima?

1. **Preparar:** reproducir la división de Iris del Laboratorio 17.
2. **Validar:** usar cinco pliegues estratificados sobre las 120 flores de entrenamiento.
3. **Comparar:** profundidades 1, 2, 3, 4 y sin límite.
4. **Seleccionar:** comparar la exactitud media y su variación.
5. **Evaluar:** entrenar el modelo elegido y medir su desempeño en las 30 flores de prueba.

Entregable: notebook con tabla comparativa, evaluación final y conclusión propia.