
Analítica de Datos

Sesión 04. Distribuciones de probabilidad e intervalos de confianza

Distribución normal, puntuación Z, variabilidad muestral e intervalos de confianza

Luis Miguel Gómez Meneses

Universidad Cooperativa de Colombia

Ingeniería de Software — Séptimo semestre

Cómo trabajaremos hoy

Bloque	Contenido	Tiempo
Quiz	Evaluación individual	60 min
Apertura	De la inferencia estadística a las distribuciones	10 min
Teoría 1	Distribuciones de probabilidad y distribución normal	25 min
Lab 10	Exploración de distribuciones con Python	25 min
Teoría 2	Regla 68–95–99.7 y Z-score	25 min
Lab 11	Distribución normal y Z-score	30 min
Teoría 3	Población, muestra, variabilidad y error estándar	20 min
Teoría 4	Intervalos de confianza	15 min
Lab 12	Intervalo de confianza del 95 % en Python	30 min

Teoría, experimentación con Python e interpretación estadística.

De la sesión anterior a esta sesión

En la sesión anterior

Utilizamos herramientas de inferencia estadística para evaluar relaciones entre variables:

- formulamos H_0 y H_1 ;
- establecimos un nivel de significancia α ;
- calculamos e interpretamos el p-value;
- tomamos decisiones a partir de una muestra.

Ahora aparece una nueva pregunta

Para utilizar muchas herramientas estadísticas necesitamos comprender **cómo se comportan los datos y qué valores podemos esperar.**

¿Cómo podemos representar estadísticamente el comportamiento de una variable?

¿Qué es una distribución?

PRIMERO OBSERVEMOS LOS DATOS

Una **distribución** describe cómo se reparten los valores de una variable y con qué frecuencia aparecen.

Al observar una distribución podemos identificar:

- dónde se concentran los valores;
- qué tan dispersos están;
- si existe simetría o asimetría;
- si aparecen valores poco frecuentes o extremos.

Idea clave

No basta con conocer la media de una variable: también necesitamos comprender **cómo se distribuyen sus valores**.

De los datos a la probabilidad

DE LO OBSERVADO A LO QUE PUEDE OCURRIR

Cuando analizamos un conjunto de datos, observamos los valores que realmente ocurrieron.

Sin embargo, en estadística también nos interesa preguntarnos:

- ¿qué valores puede tomar una variable?
- ¿qué tan probable es observar cada valor o rango de valores?

Distribución de probabilidad

Una **distribución de probabilidad** describe los posibles valores de una variable aleatoria y cómo se distribuye la probabilidad entre esos valores.

Datos observados $\longrightarrow$ **Valores posibles y su probabilidad**

¿Qué es una variable aleatoria?

DEL RESULTADO DE UN FENÓMENO A UN VALOR NUMÉRICO

Una **variable aleatoria** es una variable cuyo valor depende del resultado de un fenómeno aleatorio.

Por ejemplo:

- número de clientes que llegan a una tienda en una hora;
- tiempo que tarda un servidor en responder una solicitud;
- peso de un producto seleccionado al azar;
- número de errores encontrados en una aplicación.

Idea clave

La variable aleatoria permite representar numéricamente los posibles resultados de un fenómeno incierto.

Variables aleatorias discretas y continuas

EL TIPO DE VALORES IMPORTA

Las variables aleatorias pueden clasificarse según los valores que pueden tomar.

Variable discreta

Toma valores **separados y contables**.

Ejemplos:

- número de errores;
- número de clientes;
- número de ventas.

Variable continua

Puede tomar **cualquier valor dentro de un intervalo**.

Ejemplos:

- tiempo;
- temperatura;
- peso.

El tipo de variable determina qué distribuciones de probabilidad pueden utilizarse para modelarla.

Algunas distribuciones de probabilidad

DIFERENTES FENÓMENOS, DIFERENTES MODELOS

No existe una única distribución de probabilidad. La distribución adecuada depende del fenómeno que queremos representar.

Distribución	Tipo	Puede modelar
Binomial	Discreta	Número de éxitos
Poisson	Discreta	Conteo de eventos
Normal	Continua	Valores alrededor de una media
Exponencial	Continua	Tiempo entre eventos

¿En cuál nos concentraremos?

LA DISTRIBUCIÓN NORMAL

En esta sesión nos concentraremos en la **distribución normal**, una distribución de probabilidad para variables continuas.

Su estudio nos permitirá comprender conceptos que utilizaremos posteriormente en inferencia estadística:

- la posición de un valor respecto a la media;
- la variabilidad alrededor de la media;
- la puntuación Z ;
- los intervalos de confianza.


Pregunta

¿Qué características tiene una distribución normal y cómo podemos reconocerla?

La distribución normal

UNA DISTRIBUCIÓN CONTINUA Y SIMÉTRICA

La **distribución normal** tiene una forma característica de campana y es simétrica alrededor de su media.




Observe

Los valores tienden a concentrarse alrededor de la media, mientras que los valores más alejados son menos frecuentes.

Características de la distribución normal

1. ES SIMÉTRICA

Una distribución normal presenta la misma forma a ambos lados de su centro.



Los valores situados a la misma distancia de la media, pero en direcciones opuestas, ocupan posiciones equivalentes en la distribución.

Características de la distribución normal

¿DÓNDE SE ENCUENTRAN LOS VALORES?

2. Los valores se concentran alrededor de la media

Los valores cercanos a la media μ son **más frecuentes**.

3. Los valores extremos son menos frecuentes

A medida que nos alejamos de la media, los valores son **cada vez menos frecuentes**.

Por tanto, conocer únicamente la media no es suficiente: también necesitamos saber **qué tan dispersos están los valores alrededor de ella**.

¿Qué determina una distribución normal?

DOS PARÁMETROS FUNDAMENTALES

Una distribución normal queda determinada por dos parámetros:

Media μ

Determina el **centro** de la distribución.

Si cambia μ , la distribución se desplaza hacia la izquierda o hacia la derecha.

Desviación estándar σ

Determina la **dispersión** de los valores alrededor de la media.


Un valor mayor de σ indica una mayor dispersión.

μ indica dónde está el centro; σ indica cuánto se dispersan los valores.

¿Qué ocurre cuando cambia la desviación estándar?

MISMA MEDIA, DIFERENTE DISPERSIÓN

Dos distribuciones normales pueden tener la misma media y presentar diferente dispersión.



Interpretación

Cuanto mayor es σ , más dispersos están los valores alrededor de la media.

Laboratorio 10

EXPLORACIÓN DE DISTRIBUCIONES CON PYTHON

En este laboratorio utilizaremos Python para observar cómo diferentes variables pueden presentar distintas distribuciones.

Objetivos

- visualizar distribuciones mediante histogramas;
- reconocer diferencias en la forma de los datos;
- calcular media y desviación estándar;
- relacionar μ y σ con la forma de una distribución.

¿Qué tan cerca están los valores de la media?

VOLVAMOS A LA DISTRIBUCIÓN NORMAL

En el laboratorio observamos que la desviación estándar σ describe la dispersión de los valores alrededor de la media.

Pero ahora podemos plantear una pregunta más precisa:

Pregunta


En una distribución normal, ¿qué proporción de los valores esperamos encontrar a una, dos o tres desviaciones estándar de la media?

Esta relación puede describirse mediante la **regla 68–95–99.7**.

La regla 68–95–99.7

¿QUÉ SIGNIFICAN ESTOS PORCENTAJES?

En una distribución aproximadamente normal, la desviación estándar permite establecer qué proporción de los valores se encuentra alrededor de la media.




- 1 desviación:** $\mu - \sigma \leq X \leq \mu + \sigma \Rightarrow \approx 68\%$
2 desviaciones: $\mu - 2\sigma \leq X \leq \mu + 2\sigma \Rightarrow \approx 95\%$

La regla 68–95–99.7

TRES DESVIACIONES ESTÁNDAR

Al ampliar la distancia respecto a la media, incluimos una mayor proporción de los valores.



¿Cómo interpretamos la regla 68–95–99.7?

INTERVALOS ALREDEDOR DE LA MEDIA

En una distribución aproximadamente normal, al aumentar la distancia respecto a la media incluimos una mayor proporción de los valores.

Regla 68–95–99.7

Una desviación estándar

$$\mu - \sigma \leq X \leq \mu + \sigma \quad \Rightarrow \quad \approx 68 \%$$

Dos desviaciones estándar

$$\mu - 2\sigma \leq X \leq \mu + 2\sigma \quad \Rightarrow \quad \approx 95 \%$$

Tres desviaciones estándar

$$\mu - 3\sigma \leq X \leq \mu + 3\sigma \quad \Rightarrow \quad \approx 99.7 \%$$

Aplicamos la regla a nuestros datos

PESO DE LOS PRODUCTOS

En el Laboratorio 10 obtuvimos aproximadamente:

$$\mu = 499 \text{ g} \qquad \sigma = 25 \text{ g}$$

Aplicando la regla 68–95–99.7:

Distancia	Cálculo	Proporción
1σ	$499 \pm 25 = [474, 524]$	$\approx 68 \%$
2σ	$499 \pm 50 = [449, 549]$	$\approx 95 \%$
3σ	$499 \pm 75 = [424, 574]$	$\approx 99.7 \%$

Por ejemplo, aproximadamente el **95 % de los pesos** se encuentra entre **449 g y 549 g**.

¿Qué tan lejos está un valor de la media?

DE LOS INTERVALOS A UNA OBSERVACIÓN

La regla 68–95–99.7 nos permitió estudiar qué proporción de los valores se encuentra alrededor de la media.

Ahora pensemos en una **observación individual**.

Si el peso medio es:

$$\mu = 499 \text{ g}$$

¿qué significa observar un producto que pesa **549 g**?

No solo nos interesa conocer la diferencia en gramos. Queremos expresar esa distancia utilizando la **desviación estándar como unidad de medida**.

¿Cuántas desviaciones estándar separan una observación de la media?

La puntuación Z

MEDIR LA DISTANCIA RESPECTO A LA MEDIA

La **puntuación Z** indica cuántas desviaciones estándar se encuentra una observación por encima o por debajo de la media.

$$Z = \frac{x - \mu}{\sigma}$$

donde:

x = observación μ = media σ = desviación estándar

El valor de Z expresa la distancia respecto a la media en unidades de desviación estándar.

Aplicamos la puntuación Z

UN PRODUCTO DE 549 GRAMOS

Para la variable peso_producto tenemos:

$$x = 549 \text{ g}, \quad \mu = 499 \text{ g}, \quad \sigma = 25 \text{ g}$$

Sustituimos los valores en la fórmula:

$$Z = \frac{x - \mu}{\sigma} = \frac{549 - 499}{25} = \frac{50}{25} = 2$$

Interpretación

$Z = 2$ significa que el producto de 549 g se encuentra **2 desviaciones estándar por encima de la media**.

Aplicamos la puntuación Z

UN PRODUCTO DE 549 GRAMOS

Para la variable peso_producto tenemos:

$$x = 549 \text{ g}, \quad \mu = 499 \text{ g}, \quad \sigma = 25 \text{ g}$$

Sustituimos los valores en la fórmula:

$$Z = \frac{x - \mu}{\sigma} = \frac{549 - 499}{25} = \frac{50}{25} = 2$$

Interpretación

$Z = 2$ significa que el producto de 549 g se encuentra **2 desviaciones estándar por encima de la media**.

¿Cómo interpretamos la puntuación Z ?

EL SIGNO INDICA LA POSICIÓN

El signo de Z indica en qué lado de la media se encuentra una observación.

Valor de Z	Interpretación
$Z < 0$	La observación está por debajo de la media.
$Z = 0$	La observación coincide con la media.
$Z > 0$	La observación está por encima de la media.

El signo indica la dirección respecto a la media.

¿Qué nos dice la magnitud de Z ?

LA DISTANCIA RESPECTO A LA MEDIA

El valor absoluto $|Z|$ indica cuántas **desviaciones estándar** separan una observación de la media.

$$Z = -2 \quad \longleftarrow \quad \mu \quad \longrightarrow \quad Z = 2$$

2 desviaciones
por debajo

2 desviaciones
por encima

$Z = -2$ y $Z = 2$ están a la misma distancia de la media, pero en direcciones opuestas.

Población y muestra

NO SIEMPRE PODEMOS OBSERVAR TODO

En muchos problemas de analítica de datos queremos conocer características de un conjunto completo de elementos.

Población

Es el **conjunto completo** de individuos, objetos u observaciones que queremos estudiar.

Muestra

Es un **subconjunto de la población** que utilizamos para obtener información sobre ella.

¿Todas las muestras producen el mismo resultado?

VARIABILIDAD MUESTRAL

Supongamos que tomamos varias muestras aleatorias de una misma población y calculamos la media de cada una.

$$\text{Muestra 1} \rightarrow \bar{x}_1 = 501.2$$

$$\text{Muestra 2} \rightarrow \bar{x}_2 = 497.8$$

$$\text{Muestra 3} \rightarrow \bar{x}_3 = 500.5$$

Las medias son parecidas, pero **no son exactamente iguales**.

Esta variación entre muestras se conoce como variabilidad muestral.

¿Cómo medimos la variabilidad entre muestras?

EL ERROR ESTÁNDAR

El **error estándar de la media** mide cuánto tienden a variar las medias obtenidas de diferentes muestras.

$$SE = \frac{s}{\sqrt{n}}$$

donde:

s = desviación estándar de la muestra

n = tamaño de la muestra

¿Qué ocurre cuando aumenta la muestra?

TAMAÑO DE MUESTRA Y ERROR ESTÁNDAR

Supongamos que la desviación estándar se mantiene en:

$$s = 25$$

n	Cálculo	Error estándar
25	$\frac{25}{\sqrt{25}}$	5
100	$\frac{25}{\sqrt{100}}$	2.5
400	$\frac{25}{\sqrt{400}}$	1.25

A mayor tamaño de muestra, menor error estándar.

¿Cómo estimamos la media de una población?

DE UNA MUESTRA A LA POBLACIÓN

Normalmente no conocemos la media de toda la población.

Por eso tomamos una muestra y calculamos su media:

$$\bar{x}$$

Pero sabemos que otra muestra podría producir una media ligeramente diferente.

En lugar de estimar la media poblacional con **un único valor**, podemos construir un **intervalo de valores plausibles**.

Ese intervalo se denomina intervalo de confianza.

¿Qué significa un 95 % de confianza?

EL NIVEL DE CONFIANZA

Un intervalo de confianza se construye a partir de una muestra para estimar un parámetro desconocido de la población.

Para un nivel de confianza del **95 %**, el procedimiento utilizado está diseñado para que:

aproximadamente 95 de cada 100 intervalos contruidos a partir de muestras diferentes contengan la verdadera media poblacional μ .

El nivel de confianza expresa la **confiabilidad del procedimiento de estimación**.

Del Z-score al valor crítico

UTILIZAMOS LA DISTRIBUCIÓN NORMAL ESTÁNDAR

Ya vimos que el Z-score mide la distancia de un valor respecto a la media en desviaciones estándar.

$$Z = \frac{x - \mu}{\sigma}$$

En la distribución normal también podemos buscar valores de Z que delimiten una determinada proporción de los datos.

Para contener el **95 % central** de una distribución normal necesitamos llegar aproximadamente hasta:

$$Z = -1.96 \quad \text{y} \quad Z = 1.96$$

¿Qué estamos estimando con el intervalo?

DE LA MUESTRA A LA POBLACIÓN

Queremos conocer la **media de una población**, pero normalmente este valor es desconocido:

$$\mu = \text{media poblacional desconocida}$$

Tomamos una muestra y calculamos:

$$\bar{x} = \text{media muestral}$$

A partir de $\bar{x}$ construimos un **intervalo de confianza** para estimar dónde podría encontrarse μ .

El intervalo estima un parámetro de la población, no los valores individuales de los datos.

¿Cómo construimos el intervalo de confianza?

INTERVALO DE CONFIANZA DEL 95 %

Partimos de la media obtenida en nuestra muestra:

$$\bar{x}$$

y construimos un margen alrededor de ella utilizando el **error estándar** y el **valor crítico**.

$$\text{Margen de error} = 1.96 SE$$

Por tanto, el intervalo de confianza del 95 % es:

$$IC_{95\%} = [\bar{x} - 1.96SE, \bar{x} + 1.96SE]$$

Media muestral $\pm$ margen de error

INTERVALOS DE CONFIANZA CON PYTHON

Intervalo de confianza del 95 %

En este laboratorio utilizaremos nuevamente el dataset

`datos_distribuciones.csv`

para estimar la **media poblacional del peso de los productos** a partir de una muestra.

Población $\rightarrow$ **Muestra** $\rightarrow \bar{x} \rightarrow SE \rightarrow IC_{95\%}$