
Analítica de Datos

Sesión 05. Regresión lineal simple y múltiple

Modelos con una o varias variables predictoras,
interpretación de coeficientes y evaluación

Luis Miguel Gómez Meneses

Universidad Cooperativa de Colombia

Ingeniería de Software — Séptimo semestre

Cómo trabajaremos hoy

Bloque	Contenido	Tiempo
Evaluación	Sustentaciones y cierre del primer 20 %	60 min
Teoría 1	Regresión lineal simple: ecuación, predicción y residuos	30 min
Lab 13	Ajuste e interpretación de un modelo simple	35 min
Teoría 2	Regresión lineal múltiple: predictores y coeficientes	30 min
Lab 14	Construcción de un modelo múltiple con Python	45 min
Evaluación	Comparación de modelos: R^2 , MAE, MSE y RMSE	25 min
Cierre	Interpretación, conclusiones y actividad final	15 min

De una variable predictora a modelos con múltiples predictores.

De la sesión anterior a esta sesión

En la sesión anterior

Utilizamos una muestra para estimar un parámetro desconocido de la población:

- calculamos la media muestral;
- determinamos el error estándar;
- construimos un intervalo de confianza;
- analizamos el efecto del tamaño de la muestra.

En esta sesión

Utilizaremos una o varias variables para explicar y predecir el comportamiento de una variable respuesta:

- con un predictor: **regresión lineal simple**;
- con varios predictores: **regresión lineal múltiple**.

¿Qué es la regresión lineal simple?

DE LA RELACIÓN A LA PREDICCIÓN

La **regresión lineal simple** es un método estadístico que permite representar la relación lineal entre una variable predictora y una variable respuesta mediante una ecuación.

En este modelo intervienen:

- una variable predictora, utilizada para explicar o predecir;
- una variable respuesta, cuyo valor queremos estimar.

Idea clave

Se denomina **simple** porque utiliza una sola variable predictora para estimar el comportamiento de la variable respuesta.

Un predictor $\longrightarrow$ Modelo lineal $\longrightarrow$ Valor estimado

Variable predictora y variable respuesta

VARIABLES CON FUNCIONES DIFERENTES

En un modelo de regresión intervienen una variable respuesta y una o varias variables predictoras.

Variable predictora X

Es una variable conocida que utilizamos para explicar o estimar el comportamiento de la variable respuesta.

También se denomina:

- variable independiente;
- variable explicativa.

Variable respuesta Y

Es la variable que queremos explicar o estimar mediante el modelo.

También se denomina:

- variable dependiente;
- variable objetivo.

Regresión simple: una X

Regresión múltiple: varias X

Un problema de regresión

DE UNA PREGUNTA A DOS VARIABLES

Una empresa quiere analizar si la inversión mensual en publicidad puede utilizarse para estimar sus ventas.

Variable predictora

X = inversión en publicidad

Es la información conocida que utilizaremos para realizar la estimación.

Variable respuesta

Y = ventas

Es la variable cuyo valor queremos explicar o predecir.


Pregunta de análisis

¿Cuánto esperamos vender para una determinada inversión en publicidad?

El diagrama de dispersión

PRIMERO OBSERVAMOS LA RELACIÓN

Antes de construir el modelo, representamos cada observación mediante un punto con coordenadas (X, Y) .



¿Qué observamos?

- Los puntos presentan una tendencia ascendente.
- Cuando X aumenta, Y tiende a aumentar.
- La relación parece aproximadamente lineal.
- Los puntos no forman una recta perfecta.

¿Qué recta representa mejor la tendencia de los datos?

La ecuación de regresión lineal simple

UNA RECTA PARA REALIZAR ESTIMACIONES

La relación entre la variable predictora X y la variable respuesta Y se representa mediante:

$$\hat{Y} = \beta_0 + \beta_1 X$$

Componentes del modelo

- X : valor conocido de la variable predictora.
- $\hat{Y}$: valor de Y estimado por el modelo.
- β_0 : intercepto o punto de partida de la recta.
- β_1 : pendiente de la recta. Indica cuánto cambia $\hat{Y}$ cuando X aumenta una unidad.

El modelo utiliza un valor conocido de X para obtener una estimación $\hat{Y}$.

Valor observado y valor estimado

EL MODELO PRODUCE UNA ESTIMACIÓN

Para cada valor de X , distinguimos entre el resultado registrado en los datos y el resultado calculado por el modelo.

Valor observado Y

Es el valor real registrado en los datos.

Si la empresa vendió realmente 27 unidades:

$$Y = 27$$

Este valor proviene directamente de la observación.

Y proviene de los datos

Valor estimado $\hat{Y}$

Es el valor calculado mediante la ecuación del modelo.

Si el modelo estimó 25 unidades:

$$\hat{Y} = 25$$

Este valor constituye una predicción.

$\hat{Y}$ proviene del modelo

El residuo

DIFERENCIA ENTRE EL VALOR REAL Y LA ESTIMACIÓN

El residuo mide cuánto se aleja la predicción del valor realmente observado.

$$e = Y - \hat{Y}$$

Ejemplo

Si el valor observado es $Y = 27$ y el modelo estima $\hat{Y} = 25$, entonces:

$$e = 27 - 25 = 2$$

El modelo estimó 2 unidades menos que el valor real.

El residuo compara el resultado real con la predicción del modelo.

Interpretación del residuo

EL SIGNO INDICA LA DIRECCIÓN DEL ERROR

El signo del residuo permite saber si el modelo estimó un valor menor o mayor que el observado.

Residuo	Interpretación
---------	----------------

$e > 0$	El modelo estimó un valor menor que el observado.
---------	---

$e < 0$	El modelo estimó un valor mayor que el observado.
---------	---

$e = 0$	La estimación coincide con el valor observado.
---------	--

Idea clave

Cuanto más cercano a cero sea el residuo, más próxima será la estimación al valor observado.

La recta de mejor ajuste

UNA RECTA QUE REDUCE LOS ERRORES

Es posible dibujar diferentes rectas sobre los mismos datos, pero cada una produce estimaciones distintas.

Criterio de ajuste

Para cada observación, el modelo calcula un residuo:

$$e_i = Y_i - \hat{Y}_i$$

La regresión lineal selecciona los coeficientes β_0 y β_1 que minimizan:

$$\sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

La mejor recta es la que reduce, en conjunto, las diferencias entre los valores observados y estimados.

El coeficiente de determinación R^2

CUÁNTA VARIABILIDAD EXPLICA EL MODELO

El coeficiente de determinación mide qué proporción de la variabilidad de Y explica el modelo de regresión.

$$R^2 = 1 - \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2}$$

Interpretación

- Un valor cercano a 1 indica mayor capacidad explicativa.
- Un valor cercano a 0 indica que el modelo explica poca variabilidad de la respuesta.
- Por ejemplo, $R^2 = 0.65$ significa que el modelo explica aproximadamente el 65 % de la variabilidad observada.

El error absoluto medio

EL TAMAÑO PROMEDIO DE LOS ERRORES

El error absoluto medio, o MAE, calcula el promedio de las diferencias absolutas entre los valores observados y estimados.

$$MAE = \frac{1}{n} \sum_{i=1}^n |Y_i - \hat{Y}_i|$$

Interpretación

- Ignora el signo de los residuos.
- Se expresa en las mismas unidades de la variable respuesta.
- Un MAE menor indica predicciones más cercanas a los valores observados.

Si $MAE = 2$, las predicciones se alejan de los valores reales aproximadamente 2 unidades, en promedio.

Errores cuadráticos: MSE y RMSE

PENALIZAR LOS ERRORES GRANDES

El error cuadrático medio eleva cada residuo al cuadrado:

$$MSE = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

La raíz del error cuadrático medio se obtiene mediante:

$$RMSE = \sqrt{MSE}$$

Diferencia principal

- El MSE penaliza con mayor intensidad los errores grandes.
- El MSE queda expresado en unidades al cuadrado.
- El RMSE vuelve a las unidades originales de Y , por lo que resulta más fácil de interpretar.

DE LOS DATOS AL MODELO

En este laboratorio construiremos un modelo para estimar las ventas de una empresa a partir de su inversión en publicidad.

Pregunta de análisis

¿Podemos utilizar la inversión en publicidad para estimar las ventas?

Ruta de trabajo

1. Explorar las variables del conjunto de datos.
2. Construir el diagrama de dispersión.
3. Ajustar el modelo de regresión lineal.
4. Interpretar el intercepto y la pendiente.
5. Obtener predicciones y calcular residuos.

¿Qué es la regresión lineal múltiple?

VARIAS VARIABLES PARA ESTIMAR UNA RESPUESTA

La **regresión lineal múltiple** permite estimar una variable respuesta utilizando dos o más variables predictoras.

Su ecuación general es:

$$\hat{Y} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p$$

Componentes del modelo

- $\hat{Y}$: valor estimado de la variable respuesta.
- β_0 : intercepto o valor inicial del modelo.
- $X_1, X_2, \dots, X_p$: variables predictoras.
- $\beta_1, \beta_2, \dots, \beta_p$: cambios estimados en Y asociados con cada variable predictora.

Cada coeficiente se interpreta manteniendo constantes las demás variables del modelo.

Modelo de regresión múltiple para las ventas

TRES VARIABLES PREDICTORAS

Utilizaremos las inversiones en televisión, radio y prensa para estimar las ventas:

$$\widehat{\text{sales}} = \beta_0 + \beta_1(\text{TV}) + \beta_2(\text{radio}) + \beta_3(\text{newspaper})$$

Variables predictoras

- $X_1 = \text{TV}$
- $X_2 = \text{radio}$
- $X_3 = \text{newspaper}$

Variable respuesta

$$Y = \text{sales}$$

Ventas del producto expresadas en miles de unidades.

El modelo estimará la contribución de cada medio publicitario manteniendo constantes los demás.

Interpretación de los coeficientes

EL APOORTE ESTIMADO DE CADA VARIABLE

En el modelo:

$$\widehat{\text{sales}} = \beta_0 + \beta_1(\text{TV}) + \beta_2(\text{radio}) + \beta_3(\text{newspaper})$$

Interpretación

- β_0 : ventas estimadas cuando las inversiones en los tres medios son iguales a cero.
- β_1 : cambio estimado en las ventas por cada unidad adicional invertida en televisión.
- β_2 : cambio estimado en las ventas por cada unidad adicional invertida en radio.
- β_3 : cambio estimado en las ventas por cada unidad adicional invertida en prensa.

Cada cambio se interpreta manteniendo constantes las inversiones en los otros medios.

Regresión simple y regresión múltiple

DOS MODELOS, DIFERENTE CANTIDAD DE INFORMACIÓN

Regresión lineal simple

Utiliza una variable predictora:

$$\hat{Y} = \beta_0 + \beta_1 X$$

En nuestro caso:

$$\widehat{\text{sales}} = \beta_0 + \beta_1(\text{TV})$$

Regresión lineal múltiple

Utiliza dos o más variables predictoras:

$$\hat{Y} = \beta_0 + \sum_{j=1}^p \beta_j X_j$$

En nuestro caso utilizaremos:

TV, radio, newspaper

Un modelo con más variables puede explicar mejor las ventas, pero debemos comprobarlo mediante las métricas.

¿Mejorarán el R^2 , el MAE y el RMSE al incorporar las tres inversiones publicitarias?

INCORPORAR MÁS INFORMACIÓN AL MODELO

En este laboratorio utilizaremos las inversiones en televisión, radio y prensa para estimar las ventas.

Pregunta de análisis

¿Mejora la estimación de las ventas cuando utilizamos los tres medios publicitarios?

Ruta de trabajo

1. Definir las tres variables predictoras.
2. Dividir los datos en entrenamiento y prueba.
3. Ajustar el modelo de regresión múltiple.
4. Interpretar los coeficientes obtenidos.
5. Evaluar y comparar los dos modelos.

LABORATORIO 13

En el notebook construiremos y evaluaremos diferentes modelos para estimar las ventas:

Modelos que compararemos

- Modelo simple: TV.
- Modelo múltiple completo: TV + radio + newspaper.
- Modelo múltiple reducido: TV + radio.

¿Cuál modelo ofrece el mejor equilibrio entre desempeño predictivo y simplicidad?