Analítica de Datos

Clase 9. Agrupamiento de datos con k-means

Aprendizaje no supervisado y exploración de patrones

Luis Miguel Gómez Meneses

Universidad Cooperativa de Colombia

Ingeniería de Software — Séptimo semestre

16 de octubre de 2026

Sustentación de la Práctica 2: 10 minutos por equipo

Cómo trabajaremos hoy

Bloque	Contenido	Tiempo
Apertura	Organización e indicaciones de la sesión	10 min
Sustentaciones	Práctica 2: regresiones y ANOVA	90 min
Descanso	Pausa	15 min
Teoría	Aprendizaje no supervisado, distancias y escalamiento	25 min
Ejemplo guiado	K-means: formación de grupos y actualización de centroides	25 min
Lab 19	**Agrupamiento con k-means usando Iris**	**20 min**
Discusión	Interpretación de grupos y elección del número de clústeres	20 min
Introducción	Agrupamiento jerárquico y lectura de un dendrograma	25 min
Cierre	Comparación de métodos y preguntas de comprensión	10 min
Total	**Sustentaciones, teoría y un laboratorio**	**240 min**

Planeación estimada para 9 equipos. Cada sustentación incluye preguntas y dura máximo 10 minutos.

De predecir una respuesta a descubrir grupos

Lo que hemos trabajado: supervisado

Tenemos variables de entrada y una **respuesta conocida** para entrenar.

- Regresión: predecir un valor numérico.
- Clasificación: predecir una categoría.

Ejemplo con Iris:
Aprender a predecir la especie usando las medidas de cada flor y su etiqueta.

Lo que veremos hoy: no supervisado

Tenemos variables de entrada, pero **no usamos una respuesta objetivo** para entrenar.

- Explorar la estructura de los datos.
- Agrupar observaciones similares.

Ejemplo con Iris:
Agrupar flores según sus medidas, sin utilizar las etiquetas de especie.

Pregunta para discutir: Si agrupamos flores por sus medidas, ¿los grupos necesariamente coincidirán con las especies?

Un clúster es un grupo de observaciones similares según las variables y el criterio utilizados; no equivale necesariamente a una clase conocida.

¿Qué significa agrupar datos?

Idea central del agrupamiento

Formar grupos de observaciones que sean similares entre sí, según las variables seleccionadas y una medida de semejanza o distancia.

Ejemplo: agrupar flores

Representamos cada flor mediante:

- Longitud del pétalo.
- Ancho del pétalo.

En un gráfico de dispersión, **cada punto representa una flor**.

¿Cómo identificamos semejanzas?

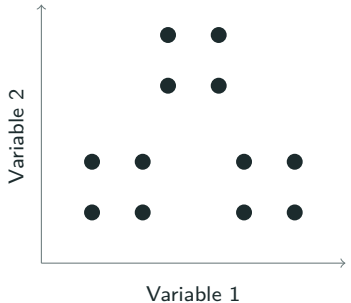
- Puntos cercanos: medidas parecidas.
- Puntos alejados: medidas diferentes.

K-means utiliza distancias para asignar cada observación a un grupo.

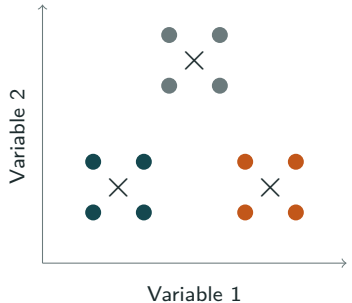
K-means: grupos alrededor de sus centros

Elegimos el número de grupos, k. El algoritmo busca un centro para cada grupo.

Datos sin agrupar



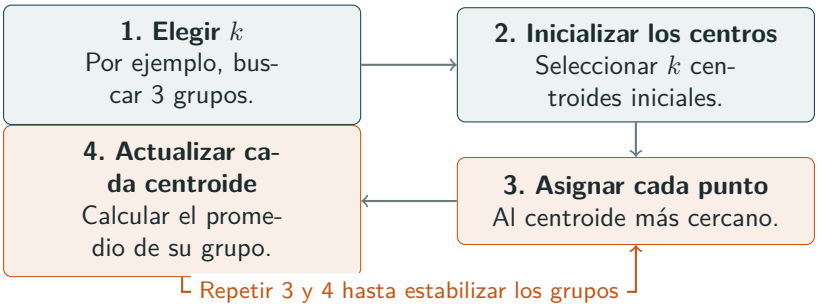
Ejemplo de resultado con $k = 3$



$\times$ **Centroide:** promedio de las coordenadas de los puntos de un grupo.

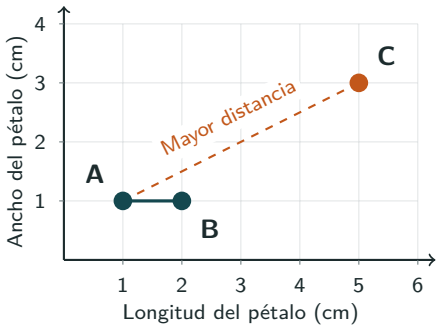
Datos ilustrativos. Los colores representan grupos encontrados, sin usar etiquetas de clase.

Cómo se forman los grupos en k-means



Pregunta: Si un centroide cambia de posición, ¿puede un punto pasar a otro grupo?

La cercanía nos ayuda a identificar semejanzas



Datos ilustrativos: cada punto representa una flor.

¿Cómo interpretamos el gráfico?

A y B están cerca:
sus medidas son más parecidas.

A y C están lejos:
sus medidas presentan mayores diferencias.

Pregunta para discutir

Si agrupamos por cercanía, ¿cuál flor sería una compañera más probable de A: B o C?

Justifica tu respuesta con el gráfico.

De la observación al cálculo de la distancia

Usamos los mismos puntos: $\mathbf{A} = (1, 1)$, $\mathbf{B} = (2, 1)$, $\mathbf{C} = (5, 3)$.

Distancia euclidiana entre dos puntos

$$d(P, Q) = \sqrt{(x_Q - x_P)^2 + (y_Q - y_P)^2}$$

Entre A y B

$$\begin{aligned} d(A, B) &= \sqrt{(2-1)^2 + (1-1)^2} \\ &= \sqrt{1+0} \\ &= \mathbf{1} \end{aligned}$$

Entre A y C

$$\begin{aligned} d(A, C) &= \sqrt{(5-1)^2 + (3-1)^2} \\ &= \sqrt{16+4} \\ &= \sqrt{20} \approx \mathbf{4{,}47} \end{aligned}$$

Interpretación: Como $1 < 4{,}47$, B está más cerca de A que C, según las dos medidas utilizadas.

¿Las unidades pueden cambiar las distancias?

Mismas flores; cambiamos únicamente la unidad del ancho.

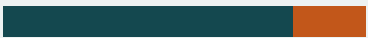
Ambas medidas en cm

A: $(1, 1)$ C: $(5, 3)$

Diferencias: longitud $= 4$; ancho $= 2$.

$$d^2 = 4^2 + 2^2 = \mathbf{20}$$

Aportes a la distancia al cuadrado:



Longitud: 80 % Ancho: 20 %

Longitud en cm; ancho en mm

A: $(1, 10)$ C: $(5, 30)$

Diferencias: longitud $= 4$; ancho $= 20$.

$$d^2 = 4^2 + 20^2 = \mathbf{416}$$

Aportes a la distancia al cuadrado:



Longitud: 3,8 % Ancho: 96,2 %

Idea clave: Al usar los valores sin ajustar su escala, el ancho domina la distancia por el cambio de unidad.

Estandarizar: poner las variables en una escala comparable

Transformamos cada variable por separado

Restamos su media y dividimos entre su desviación estándar.

$$z = \frac{x - \mu}{\sigma}$$

- x Valor original.
- μ Media de la variable.
- σ Desviación estándar.

Para una variable no constante, los valores transformados tienen **media 0** y **desviación estándar 1**.

Ejemplo ilustrativo: longitud del pétalo

Valor: 5 cm. Media: 3 cm.

Desviación estándar: 2 cm.

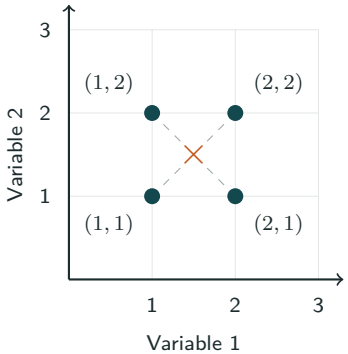
$$z = \frac{5 - 3}{2} = \mathbf{1}$$



La flor está **una desviación estándar por encima de la media**.

El centroide es el promedio de un grupo

Ejemplo ilustrativo: estos cuatro puntos pertenecen al mismo grupo.



× Centroide del grupo

Promediamos cada coordenada

$$c_x = \frac{1+1+2+2}{4} = 1{,}5$$

$$c_y = \frac{1+2+1+2}{4} = 1{,}5$$

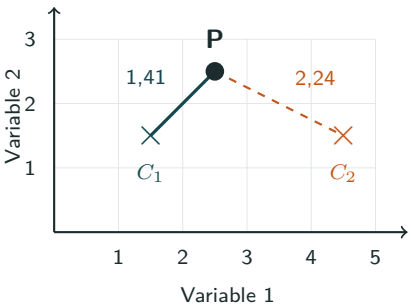
Centroide: $\mathbf{c} = (\mathbf{1{,}5};\ \mathbf{1{,}5})$.

El centroide puede ocupar una posición donde **no hay una observación**.

Pregunta: Si añadimos al grupo un punto muy alejado hacia la derecha, ¿hacia dónde se moverá el centroide?

¿A qué grupo asignamos el punto P?

Centroides actuales: $C_1 = (1{,}5;\ 1{,}5)$ y $C_2 = (4{,}5;\ 1{,}5)$. Punto: $P = (2{,}5;\ 2{,}5)$.



Comparamos las dos distancias

$$d(P, C_1) = \sqrt{1^2 + 1^2} \approx 1{,}41$$

$$d(P, C_2) = \sqrt{(-2)^2 + 1^2} \approx 2{,}24$$

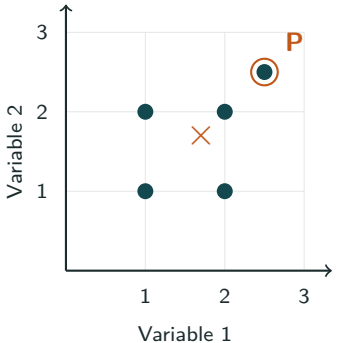
Como $1{,}41 < 2{,}24$, **asignamos P al grupo 1**.

Su centroide actual es el más cercano.

Siguiente paso: repetimos la comparación para todos los puntos y después recalculamos los centroides.

El centroide cambia al cambiar su grupo

El grupo 1 contiene ahora **5 puntos**, incluido $P = (2{,}5;\ 2{,}5)$.



× Centroide actualizado

Recalculamos el promedio con 5 puntos

$$c_x = \frac{1+1+2+2+2{,}5}{5} = 1{,}7$$

$$c_y = \frac{1+2+1+2+2{,}5}{5} = 1{,}7$$

Antes: $C_1 = (1{,}5;\ 1{,}5)$.

Ahora: $C_1 = (1{,}7;\ 1{,}7)$.

El centroide se desplazó hacia P.

El ciclo continúa: tras actualizar todos los centroides, volvemos a asignar cada punto al centro más cercano.

¿Cuándo termina k-means?

Repetimos la asignación y la actualización

El proceso busca estabilizar los grupos y sus centroides. En la implementación, puede detenerse cuando el movimiento de los centros es muy pequeño o alcanza el máximo de iteraciones.

Los centros iniciales pueden cambiar el resultado

Distintas inicializaciones pueden producir agrupamientos diferentes. Por eso podemos ejecutar varios intentos y conservar el de menor suma de distancias al cuadrado entre los puntos y sus centroides.

En el laboratorio: usaremos 10 inicializaciones y una semilla fija para poder reproducir el resultado.

Laboratorio 19: agrupamiento de flores con k-means

Objetivo

Agrupar las flores de Iris usando la longitud y el ancho del pétalo, sin utilizar las etiquetas de especie durante el ajuste.

Actividad	Tiempo
Cargar Iris y seleccionar las dos variables	3 min
Estandarizar y ajustar k-means con $k = 3$	5 min
Visualizar los grupos y sus centroides	5 min
Interpretar los resultados y responder las preguntas	7 min

Elegimos $k = 3$ como ejemplo didáctico. Los números de los grupos son identificadores, no nombres de especies.

¿Qué patrones encontramos en los grupos?

Resultados con las dos variables y la configuración del laboratorio.

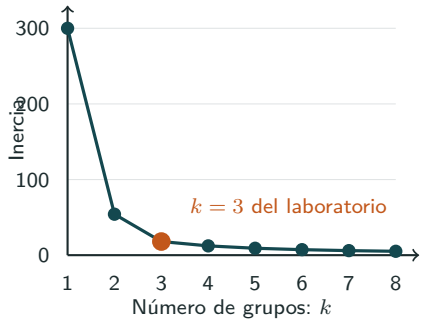
Perfil del grupo	Flores	Longitud media (cm)	Ancho medio (cm)
Pétalos cortos y estrechos	50	1,46	0,25
Pétalos intermedios	52	4,30	1,33
Pétalos largos y anchos	48	5,57	2,06

Un grupo no equivale automáticamente a una especie

K-means agrupó las flores por sus medidas. Para estudiar la correspondencia con las especies, debemos comparar después los grupos con las etiquetas reales.

Pregunta: ¿Basta conocer el promedio de un grupo para saber si sus puntos están muy juntos o dispersos?

Elección de k: método del codo



¿Qué mide la inercia?

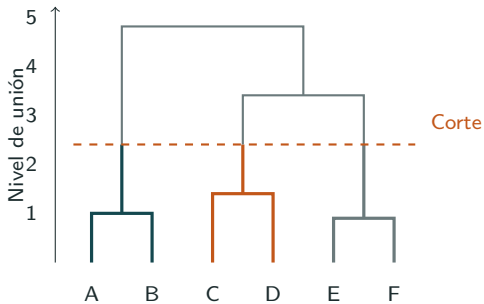
La suma de las distancias al cuadrado de cada punto al centroide de su grupo.

Buscamos un cambio de pendiente: un punto a partir del cual añadir grupos reduce mucho menos la inercia.

El codo orienta la elección, pero puede ser ambiguo.

Pregunta: ¿Qué cambia en la reducción de inercia después de $k = 3$?

Agrupamiento jerárquico: lectura de un dendrograma



Esquema ilustrativo con seis observaciones.

Enfoque aglomerativo

Cada observación comienza como un grupo. El método fusiona grupos sucesivamente según un criterio de enlace.

Leemos el árbol de abajo hacia arriba.

El corte dibujado atraviesa tres ramas: **obtenemos 3 grupos**.

$\{A, B\}$, $\{C, D\}$ y $\{E, F\}$.

K-means y agrupamiento jerárquico

Aspecto	K-means	Jerárquico aglomerativo
Número de grupos	Elegimos k antes de ajustar el modelo.	Elegimos un corte en el dendrograma.
Formación	Asigna puntos a centroides y actualiza los promedios.	Fusiona grupos sucesivamente mediante un criterio de enlace.
Resultado	Una partición en k grupos.	Un árbol que permite explorar diferentes niveles de agrupamiento.

Preguntas de cierre

1. ¿Por qué cambiar las unidades puede cambiar el resultado de k-means?
2. ¿Qué método permite observar cómo los grupos se unen a diferentes niveles?